

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



TOÁN ỨNG DỤNG THỐNG KÊ

ĐỒ ÁN 02: Data fitting vs OLS

Nhóm: 02
Lớp: 24CTT1
Mã học phần: MTH00051
Giảng viên hướng dẫn: Võ Nam Thục Đoan
Lê Nhựt Nam

Thành phố Hồ Chí Minh, ngày 30 tháng 05 năm 2026

Mục lục

Lời Nói Đầu	5
Lời Cam Đoan	6
Danh sách thành viên và Phân công nhiệm vụ	7
Mục Tiêu Đồ Án	8
Cấu Trúc Báo Cáo	8
Bảng Giải Thích Thuật Ngữ	8
Phần 1 Lý Thuyết Data Fitting và Minh Họa	14
1 Giới Thiệu	14
1.1 Đặt Vấn Đề	14
2 Lý Thuyết	15
2.1 Mô Hình Hồi Quy Tuyến Tính	15
2.1.1 Các Giả Thiết Gauss-Markov	15
2.2 Phương Pháp Bình Phương Tối Thiểu Thông Thường	16
2.2.1 Hàm Mất Mát và Nghiệm Giải Tích	16
2.2.2 Ước Lượng Phương Sai Nhiễu	18
2.2.3 Ý Nghĩa Hình Học Của OLS	18
2.2.4 Đánh Giá Mô Hình	18
2.3 Phân Tích Phần Dư	19
2.3.1 Phần Dư Chuẩn Hóa và Khoảng Cách Cook	19
2.3.2 Các Biểu Đồ Chẩn Đoán	19
2.4 Chính Quy Hóa Ridge và Lasso	21
2.4.1 Hồi Quy Ridge	21
2.4.2 Hồi Quy Lasso	22
2.4.3 So Sánh Ridge và Lasso	24
2.5 Kiểm Chứng Chéo K-lần	25
2.5.1 Tiêu Chí Thông Tin AIC và BIC (Lựa chọn thay thế)	27
3 Kết Quả Minh Họa	28
3.1 Cài Đặt Hồi Quy OLS và Kiểm Chứng	28
3.2 Ma Trận Chiếu và Các Tính Chất	29
3.3 Các Chỉ Số Đánh Giá Mô Hình	30

3.4	Suy Diễn Thống Kê Hệ Số Hồi Quy	30
3.5	Phát Hiện Đa Cộng Tuyến Bằng VIF	31
3.6	Chính Quy Hóa Ridge và Lasso	32
3.6.1	Ridge Trace	32
3.6.2	Lasso và Cơ Chế Chọn Biến	33
3.6.3	Chọn λ^* Bằng Kiểm Chứng Chéo	33
3.7	Phân Tích Phần Dư	34
3.8	Kiểm Chứng Chéo K-lần	35
3.9	Minh Họa Định Lý Gauss–Markov Bằng Monte Carlo	36
3.10	Hệ Thống Kiểm Thử Đơn Vị Tự Động	37
3.11	Tóm Tắt Kết Quả Phần 1	38
Phần 2 Ứng Dụng Data Fitting vào Dữ Liệu Thực		39
4	Mô Tả Bộ Dữ Liệu	39
4.1	Lý Do Lựa Chọn	39
4.2	Tổng Quan Dataset	39
4.3	Mô Tả Các Biến	40
4.4	Phân Phối Biến Mục Tiêu	41
5	Phương Pháp	41
5.1	Khảo Sát Dữ Liệu (EDA)	41
5.1.1	Thống Kê Mô Tả	42
5.1.2	Phân Phối và Phát Hiện Outliers	43
5.1.3	Ma Trận Tương Quan	47
5.1.4	Phân Tích Missing Values	48
5.1.5	Tổng Kết Giai Đoạn EDA	49
5.2	Tiền Xử Lý Dữ Liệu	49
5.2.1	Xử Lý Missing Values	50
5.2.2	Xử lý Outliers	51
5.2.3	Chuẩn Hóa Dữ Liệu	54
5.2.4	Feature Engineering	55
5.2.5	Tổng Quan Pipeline	55
5.3	Xây Dựng Mô Hình	57
5.3.1	Mô Hình 1 — OLS Cơ Bản	58
5.3.2	Mô Hình 2 — OLS Chọn Biến	60
5.3.3	Mô Hình 3 — Hồi Quy Ridge với Kiểm Chứng Chéo	61
5.3.4	Mô Hình 4 — Bayesian	62

5.3.5	Mô Hình 5 — Kernel RBF	64
6	Kết Quả và Đánh Giá	65
6.1	Bảng So Sánh Các Mô Hình	65
6.2	Phân Tích Tầm Quan Trọng Đặc Trưng	66
6.3	Phân Tích Phần Dư - Mô Hình Kernel RBF	67
6.4	Phân Tích Tầm Quan Trọng Đặc Trưng	70
7	Kết Luận	71
7.1	Tóm Tắt Kết Quả	71
7.1.1	Phần 1 - Data Fitting	71
7.1.2	Phần 2 - Ứng dụng Data Fitting vào dữ liệu thực tế	71
7.2	Bài Học Rút Ra	72
7.2.1	Về lý thuyết	72
7.2.2	Về thực tiễn	73
7.3	Hướng Mở Rộng	73
8	Tài liệu tham khảo	74
A	Mã Nguồn Chính	75
B	Cấu Trúc Thư Mục	75

Lời Nói Đầu

Trong bối cảnh khoa học dữ liệu và học máy ngày càng đóng vai trò cốt lõi trong mọi lĩnh vực, phương pháp *Data Fitting* — đặc biệt là hồi quy tuyến tính — vẫn là nền tảng không thể thiếu cho bất kỳ hệ thống phân tích và dự báo nào. Đồ án “**Data Fitting vs OLS**” không chỉ đơn thuần là một bài tập lớn, mà còn là cơ hội để nhóm chúng em đi sâu vào bản chất toán học của phương pháp bình phương tối thiểu thông thường, hiểu rõ các tính chất hình học và thống kê ẩn sau mỗi công thức, đồng thời tự tay cài đặt hoàn chỉnh từ phép toán ma trận cơ bản cho đến các kỹ thuật chính quy hóa hiện đại.

Qua quá trình nghiên cứu và triển khai, nhóm đã xây dựng được một bộ thư viện đại số tuyến tính tự viết bằng Python, cài đặt toàn bộ các thuật toán OLS, Ridge, Lasso, kiểm chứng chéo K-lần và mô phỏng Monte Carlo mà không phụ thuộc vào các thư viện tính toán bên ngoài cho phần lõi. Kết quả thực nghiệm trên cả dữ liệu mô phỏng lẫn dữ liệu thực tế đã giúp chúng em củng cố và mở rộng kiến thức nền tảng, đặt bước đệm vững chắc cho các môn học chuyên ngành tiếp theo.

Dù đã nỗ lực hết sức và nghiêm túc trong quá trình hoàn thiện đồ án, song do những giới hạn về mặt thời gian cũng như kinh nghiệm thực tiễn, báo cáo này chắc chắn vẫn còn những thiếu sót nhất định. Chúng em rất mong nhận được sự đánh giá, góp ý quý báu từ quý Thầy Cô để nhóm có thể đúc kết thêm kinh nghiệm và hoàn thiện bản thân hơn trong những chặng đường học tập tiếp theo.

Chúng em xin chân thành cảm ơn!

Lời Cam Đoan

Chúng em, Nhóm 02, xin cam đoan đây là đồ án tự nghiên cứu và cài đặt của cả nhóm. Các dòng mã nguồn, phân tích thuật toán, cấu trúc dữ liệu và logic xử lý đều được nhóm tự cài đặt từ đầu bằng Python theo đúng yêu cầu của đồ án. Cụ thể:

- Toàn bộ thư viện đại số tuyến tính (`matrix_ops.py`): các phép nhân ma trận, nghịch đảo, chuyển vị, giải hệ bằng Gauss-Jordan đều được nhóm tự viết, hoàn toàn không sử dụng các hàm tính toán có sẵn của NumPy/SciPy.
- Các hàm hồi quy `ols_fit`, `hat_matrix`, `ridge_fit`, `lasso_fit_cd`, `kfold_cv`, `residual_plots` đều được xây dựng dựa trên các phép toán tự cài đặt nói trên.
- Thư viện bên ngoài (NumPy, scikit-learn, matplotlib) chỉ được dùng cho mục đích kiểm chứng kết quả, sinh dữ liệu mô phỏng, hoặc vẽ biểu đồ trực quan, không thay thế cho phần cài đặt chính của nhóm.

Mọi kết quả kiểm thử, số liệu thực nghiệm được trình bày trong báo cáo này là hoàn toàn trung thực, phản ánh đúng kết quả thực thi từ mã nguồn của nhóm. Nếu có bất kỳ sự vi phạm đạo đức học thuật nào, chúng em xin hoàn toàn chịu trách nhiệm trước giảng viên hướng dẫn và Khoa Công nghệ Thông tin, Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM.

Đại diện nhóm

Phạm Minh Trọng

Danh sách thành viên và Phân công nhiệm vụ

STT	Họ và Tên	Nhiệm vụ phân công	Hoàn thành
1	Phạm Minh Trọng (24120151 - Leader)	Phân công nhiệm vụ, quản lý tiến độ, lập trình và kiểm thử unit test cho thuật toán hồi quy OLS (<code>ols_implementation.py</code> , <code>test_part1_unit.py</code>). Soạn thảo phần Giới thiệu, Đặt vấn đề (<code>p1_intro.tex</code>) và Lời mở đầu.	100%
2	Đào Tiến Đạt (24120033)	Lập trình thư viện đại số tuyến tính từ đầu (<code>matrix_ops.py</code>) bao gồm các phép toán ma trận/vector và thuật toán khử Gauss chọn phần tử chốt lớn nhất. Biên soạn nội dung lý thuyết OLS và các đặc tính toán học của ma trận chiều (<code>p1_theory.tex</code>).	100%
3	Bùi Nhật Bảo (24120167)	Thiết kế và lập trình đường ống tiền xử lý dữ liệu (<code>AirQualityPipeline</code> trong <code>data_pipeline.py</code>) gồm xử lý missing bằng hồi quy OLS, chuẩn hóa Robust, Log-transform và mã hóa. Biên soạn nội dung Mô tả dữ liệu (<code>p2_dataset.tex</code>) và EDA (<code>p2_method.tex</code>).	100%
4	Trịnh Kim Mai (24120199)	Lập trình thuật toán hồi quy Ridge (nghiệm đóng) và hồi quy Lasso bằng phương pháp Coordinate Descent kết hợp toán tử ngưỡng mềm (<code>ridge_lasso.py</code>), vẽ đồ thị Ridge Trace. Biên soạn lý thuyết về chính quy hóa và giải thuật Lasso (<code>p1_theory.tex</code>).	100%
5	Trần Công Quang (24120221)	Lập trình thuật toán K-Fold Cross Validation (<code>cross_validation.py</code>) để chọn λ , thuật toán chẩn đoán phần dư (<code>residual_analysis.py</code>), và mở rộng hai mô hình nâng cao: Bayesian Regression và Kernel Ridge (<code>advanced_methods.py</code>). Biên soạn các phần kết quả thực nghiệm và kết luận (<code>p1_results.tex</code> , <code>p2_results.tex</code> , <code>p2_conclusion.tex</code>).	100%

Bảng 1: Chi tiết phân công nhiệm vụ của các thành viên trong nhóm đối với Đề án 2

Mục Tiêu Đồ Án

Đồ án này được thực hiện nhằm đạt được các mục tiêu cốt lõi sau:

1. Nắm vững nền tảng toán học của Data Fitting và tự cài đặt thuật toán Ordinary Least Squares (OLS) từ đầu bằng ngôn ngữ Python, không sử dụng các hàm giải có sẵn như sklearn hay numpy.linalg.lstsq.
2. Trình bày chứng minh toán học và minh họa bằng lập trình các kết quả lý thuyết quan trọng như đặc tính của Ma trận chiều và Định lý Gauss-Markov.
3. Khảo sát các kỹ thuật hồi quy nâng cao như xử lý Đa cộng tuyến, Chính quy hóa (Ridge và Lasso) và Xác thực chéo.
4. Vận dụng toàn bộ kiến thức vào một pipeline phân tích bộ dữ liệu thực tế: từ bước khảo sát (EDA), xử lý dữ liệu khuyết thiếu, đến huấn luyện và đánh giá mô hình toàn diện.

Cấu Trúc Báo Cáo

Báo cáo đồ án được cấu trúc thành hai phần chính, mang tính bổ trợ cho nhau:

- **Phần 1: Lý thuyết Data Fitting và Minh họa.** Tập trung trình bày chi tiết các công thức toán học, định lý liên quan đến phương pháp OLS, các phép kiểm định mô hình và các minh họa thuật toán trên dữ liệu giả lập.
- **Phần 2: Ứng Dụng Data Fitting vào dữ liệu thực tế.** Trình bày báo cáo về quy trình áp dụng mô hình hồi quy tuyến tính trên một bộ dữ liệu thực, bao gồm các bước tiền xử lý, so sánh mô hình, phân tích phần dư và kết luận ý nghĩa thực tiễn.

Bảng Giải Thích Thuật Ngữ

Để tăng tính mạch lạc và dễ theo dõi, Bảng 2 tóm tắt các thuật ngữ chuyên ngành cốt lõi được dùng xuyên suốt báo cáo. Các thuật ngữ này được liên kết về bảng tra cứu khi xuất hiện ở các phần sau.

Thuật ngữ	Tiếng Anh / Ký hiệu	Ý nghĩa và vai trò trong mô hình
Bình phương tối thiểu thông thường	OLS	Phương pháp tìm hệ số hồi quy bằng cách cực tiểu hóa tổng bình phương phần dư (RSS).
Ma trận thiết kế	Design Matrix	Ma trận chứa các biến độc lập $\mathbf{X}$, với cột đầu tiên là vector toàn số 1 biểu diễn hằng số chặn.
Ước lượng BLUE	BLUE	Ước lượng tuyến tính không chệch tốt nhất (Best Linear Unbiased Estimator) của OLS dưới các giả thiết Gauss-Markov.
Tổng bình phương phần dư	RSS	Thước đo tổng bình phương các sai lệch giữa giá trị quan sát thực tế và giá trị dự đoán của mô hình.
Tổng bình phương sai lệch toàn phần	TSS	Thước đo tổng mức độ biến thiên của biến phụ thuộc xung quanh giá trị trung bình mẫu.
Hệ số xác định	$R^2 / \bar{R}^2$	Tỷ lệ sự biến thiên của biến phụ thuộc được giải thích bởi mô hình hồi quy tuyến tính.
Ma trận chiếu	Hat Matrix ($\mathbf{H}$)	Ma trận $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$, dùng để chiếu vector $\mathbf{y}$ sang vector dự đoán $\hat{\mathbf{y}}$.
Đòn bẩy	Leverage (h_{ii})	Phần tử trên đường chéo chính của ma trận chiếu $\mathbf{H}$, phản ánh độ xa của quan sát so với trung bình mẫu.
Hệ số phóng đại phương sai	VIF	Variance Inflation Factor, chỉ số định lượng mức độ phình to phương sai của hệ số do ảnh hưởng của đa cộng tuyến.
Phần dư chuẩn hóa	Standardized Residual	Phần dư thông thường chia cho độ lệch chuẩn ước lượng của nó nhằm phục vụ chẩn đoán trên cùng một thang đo.

Bảng 2: Bảng giải thích thuật ngữ chuyên ngành

Thuật ngữ	Tiếng Anh / Ký hiệu	Ý nghĩa và vai trò trong mô hình
Khoảng cách Cook	Cook's Distance (D_i)	Độ đo mức độ thay đổi của các giá trị dự báo khi loại bỏ một quan sát cụ thể ra khỏi tập dữ liệu.
Chính quy hóa	Regularization	Kỹ thuật thêm số hạng phạt (chuẩn L_1 hoặc L_2) vào hàm mất mát để kiểm soát sự quá khớp (overfitting).
Hồi quy Ridge	Ridge Regression	Phương pháp chính quy hóa sử dụng chuẩn phạt L_2 để thu nhỏ hệ số về gần 0, giải quyết đa cộng tuyến.
Hồi quy Lasso	Lasso Regression	Phương pháp chính quy hóa sử dụng chuẩn phạt L_1 có thể triệt tiêu hoàn toàn một số hệ số về 0 để tự động chọn biến.
Hạ tọa độ	Coordinate Descent	Thuật toán tối ưu hóa lặp tuần tự theo từng tọa độ hệ số trong khi giữ cố định các tọa độ còn lại, dùng cho Lasso.
Ngưỡng mềm	Soft-thresholding	Toán tử co rút phi tuyến được áp dụng cho Lasso giúp kéo hệ số về đúng 0 nếu giá trị tương quan nhỏ hơn ngưỡng phạt.
Kiểm chứng chéo K-lần	K-Fold Cross-Validation	Phương pháp phân đoạn và huấn luyện luân phiên trên dữ liệu nhằm chọn ra siêu tham số λ^* tối ưu một cách khách quan.
Mô phỏng Monte Carlo	Monte Carlo Simulation	Phương pháp thực nghiệm lặp nhiều lần với mẫu ngẫu nhiên để đánh giá hành vi thống kê của các ước lượng.
Quá khớp	Overfitting	Hiện tượng mô hình học quá kỹ các nhiễu ngẫu nhiên trong dữ liệu huấn luyện, làm giảm hiệu năng trên dữ liệu mới.
Đánh đổi Độ chệch - Phương sai	Bias-Variance Tradeoff	Sự đánh đổi giữa sai số hệ thống do giả thiết đơn giản (Bias) và sai số do độ nhạy bén quá mức với mẫu thử (Variance).
Tiêu chí thông tin Akaike	AIC	Chỉ số đánh giá mô hình dựa trên độ khớp RSS và hình phạt số lượng tham số $2(p+2)$.
Tiêu chí thông tin Bayes	BIC	Chỉ số đánh giá mô hình dựa trên độ khớp RSS và hình phạt số lượng tham số $(p+2) \ln n$, phạt nặng hơn AIC.

Bảng 3: Bảng giải thích thuật ngữ chuyên ngành (tiếp theo)

Thuật ngữ	Tiếng Anh / Ký hiệu	Ý nghĩa và vai trò trong mô hình
Chỉ số chất lượng không khí	AQI	Biến mục tiêu cần dự báo trong bài toán, phản ánh mức độ ô nhiễm không khí tổng hợp tại từng thời điểm và thành phố.
Nhóm chất lượng không khí	AQI_Bucket	Nhãn phân loại mức độ ô nhiễm theo khoảng AQI, hỗ trợ diễn giải kết quả dự báo theo các mức chất lượng không khí.
Nhóm khí nitơ oxit	NO, NO ₂ , NO _x	Các chất ô nhiễm liên quan đến quá trình đốt nhiên liệu và giao thông, đồng thời có nguy cơ gây đa cộng tuyến trong mô hình.
Hợp chất hữu cơ dễ bay hơi	Benzene, Toluene, Xylene	Nhóm biến phản ánh ô nhiễm hữu cơ bay hơi, thường liên quan đến khí thải giao thông và hoạt động công nghiệp.
Giá trị khuyết thiếu	Missing Values	Các ô dữ liệu không có giá trị quan sát, cần được xử lý trước khi huấn luyện để tránh làm sai lệch mô hình.
Điểm ngoại lai	Outliers	Các quan sát có giá trị bất thường so với phần lớn dữ liệu, có thể ảnh hưởng mạnh đến hệ số hồi quy và sai số dự báo.

Bảng 4: Bảng giải thích thuật ngữ dữ liệu thực nghiệm

Thuật ngữ	Tiếng Anh / Ký hiệu	Ý nghĩa và vai trò trong mô hình
Tập huấn luyện	Training Set	Phần dữ liệu dùng để mô hình học quy luật, ước lượng hệ số và điều chỉnh trọng số trong quá trình huấn luyện.
Tập kiểm thử	Test Set	Phần dữ liệu độc lập không tham gia huấn luyện, dùng để đánh giá khả năng dự báo của mô hình trên dữ liệu mới.
Mức hiệu suất cơ sở	Baseline	Mốc so sánh ban đầu, thường là mô hình đơn giản, dùng để đánh giá lợi ích của các mô hình nâng cao hơn.
Tính tái lập	Reproducibility	Khả năng chạy lại quy trình và thu được kết quả nhất quán, thường được đảm bảo bằng cách cố định <code>random_state</code> .
Chọn biến	Feature Selection	Quá trình giữ lại các đặc trưng quan trọng và loại bỏ biến kém ý nghĩa hoặc gây nhiễu cho mô hình.
Loại bỏ lùi	Backward Elimination	Chiến lược chọn biến bằng cách bắt đầu từ mô hình đầy đủ rồi loại dần biến dựa trên tiêu chí như p-value hoặc VIF.
Giá trị p	p-value	Chỉ số kiểm định ý nghĩa thống kê của hệ số hồi quy; giá trị nhỏ cho thấy biến có bằng chứng đóng góp vào mô hình.
Siêu tham số	Hyperparameter	Tham số được chọn trước hoặc dò tìm ngoài quá trình học trực tiếp, ví dụ λ , γ hoặc số fold kiểm chứng chéo.
Tìm kiếm lưới	Grid Search	Phương pháp thử nhiều tổ hợp siêu tham số trên một lưới giá trị để chọn cấu hình cho sai số thấp nhất.
Mẹo hạt nhân	Kernel Trick	Kỹ thuật tính độ tương đồng trong không gian đặc trưng cao chiều mà không cần ánh xạ trực tiếp từng tọa độ mới.
Hàm nhân RBF	Radial Basis Function	Hàm nhân phi tuyến đo độ tương đồng theo khoảng cách, giúp Kernel Ridge mô hình hóa các quan hệ cong và cục bộ.
Hệ số gamma	γ	Siêu tham số kiểm soát độ lan tỏa của hàm RBF; giá trị lớn làm mô hình phản ứng cục bộ hơn với từng điểm dữ liệu.
Cường độ điều chuẩn	λ	Siêu tham số kiểm soát mức phạt lên độ lớn hệ số, giúp hạn chế quá khớp và ổn định nghiệm hồi quy.
Khoảng tin cậy	Confidence Interval	Khoảng biểu diễn độ bất định xung quanh dự báo, hỗ trợ đánh giá rủi ro thay vì chỉ dùng một giá trị dự báo điểm.
Độ bất định	Uncertainty	Mức không chắc chắn của dự báo, đặc biệt quan trọng trong các tình huống ô nhiễm cực đoan hoặc dữ liệu biến động mạnh.

Bảng 5: Bảng giải thích thuật ngữ xây dựng mô hình

Thuật ngữ	Tiếng Anh / Ký hiệu	Ý nghĩa và vai trò trong mô hình
Sai số tuyệt đối trung bình	MAE	Trung bình độ lệch tuyệt đối giữa giá trị thực tế và giá trị dự báo, giúp đo sai số theo cùng đơn vị với AQI.
Sai số bình phương trung bình căn	RMSE	Căn bậc hai của trung bình bình phương sai số, nhạy hơn với các dự báo sai lớn tại các đỉnh ô nhiễm.
Khả năng giải thích	Interpretability	Mức độ con người có thể hiểu được vai trò của các biến và cơ chế ra quyết định của mô hình.
Tầm quan trọng đặc trưng	Feature Importance	Thuốc đo mức ảnh hưởng tương đối của từng biến đầu vào lên giá trị dự báo của mô hình.
Chẩn đoán phần dư	Residual Diagnostics	Tập hợp biểu đồ và kiểm tra thống kê dùng để đánh giá sai số còn lại sau khi mô hình dự báo.
Phần dư	Residuals	Sai lệch giữa giá trị quan sát thực tế và giá trị dự báo, phản ánh phần thông tin mô hình chưa giải thích được.
Phương sai không đồng đều	Heteroscedasticity	Hiện tượng độ phân tán của phần dư thay đổi theo mức dự báo, làm mô hình kém ổn định ở một số vùng dữ liệu.
Biểu đồ Q-Q	Q-Q Plot	Biểu đồ so sánh phân vị của phần dư với phân phối chuẩn để kiểm tra giả định về dạng phân phối sai số.
Đuôi dày	Fat Tails	Hiện tượng phân phối có nhiều giá trị cực đoan hơn phân phối chuẩn, thường xuất hiện khi có các sự kiện ô nhiễm hiếm gặp.
Biểu đồ thực tế–dự báo	Actual vs Predicted Plot	Biểu đồ đối chiếu trực tiếp giá trị thật và giá trị dự báo để đánh giá mức độ bám sát đường lý tưởng $y = x$.
Tự tương quan	Autocorrelation	Hiện tượng sai số tại một thời điểm có liên hệ với sai số ở các thời điểm trước đó.
Hàm tự tương quan	ACF	Công cụ đo mức phụ thuộc của chuỗi phần dư theo các độ trễ thời gian khác nhau.
Độ trễ	Lag	Khoảng cách thời gian giữa hai quan sát, dùng khi kiểm tra tự tương quan trong chuỗi sai số.
Ngoại lai có ảnh hưởng	Influential Outlier	Quan sát bất thường có khả năng làm thay đổi đáng kể hệ số hoặc đường dự báo của mô hình.
Khả năng tổng quát hóa	Generalization	Khả năng duy trì hiệu suất tốt trên dữ liệu mới chưa từng xuất hiện trong quá trình huấn luyện.

Bảng 6: Bảng giải thích thuật ngữ đánh giá mô hình

PHẦN 1

Lý Thuyết Data Fitting và Minh Họa

1 Giới Thiệu

Trong thực tiễn, việc phân tích và tìm ra mối liên hệ toán học giữa các biến số là một nhu cầu thiết yếu trong nhiều lĩnh vực như kinh tế học, y sinh, dự báo thời tiết hay định giá bất động sản. Khởi nguồn từ bài toán dự báo, Data Fitting cung cấp nền tảng toán học vững chắc để xây dựng các mô hình tối ưu giải thích sự phụ thuộc này từ các bộ dữ liệu quan trắc.

1.1 Đặt Vấn Đề

Trong lĩnh vực phân tích dữ liệu và học máy, Data Fitting (khớp dữ liệu) là một bài toán nền tảng. Giả sử chúng ta có một tập dữ liệu quan sát được $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$, trong đó $x_i \in \mathbb{R}^p$ biểu diễn các đặc trưng đầu vào (biến độc lập) và $y_i \in \mathbb{R}$ là mục tiêu cần dự đoán (biến phụ thuộc). Bài toán đặt ra là tìm kiếm một hàm số $f: \mathbb{R}^p \rightarrow \mathbb{R}$ sao cho giá trị dự đoán $\hat{y}_i = f(x_i)$ bám sát nhất với giá trị thực tế y_i theo một tiêu chí đánh giá sai số nhất định.

Trong khuôn khổ của báo cáo này, nhóm tập trung nghiên cứu mô hình Hồi quy tuyến tính. Đây là một phương pháp tiếp cận cơ bản nhưng mạnh mẽ, dựa trên giả định rằng mối quan hệ giữa các biến đầu vào và đầu ra là tuyến tính. Mục tiêu của báo cáo là trình bày cơ sở toán học của mô hình, phương pháp tối ưu hóa hàm mất mát để ước lượng tham số, cũng như các giả thiết thống kê cần thiết để mô hình đạt được hiệu quả tốt nhất.

2 Lý Thuyết

Phần này trình bày các công thức nền tảng và đối chiếu trực tiếp với mã nguồn trong thư mục Project2_TUDDTK/part1. Toàn bộ đại số tuyến tính được tự cài đặt, không dùng NumPy/SciPy. Các thuật ngữ chuyên ngành, ký hiệu và vai trò toán học của chúng được định nghĩa chi tiết tại Bảng 2 (Mục) của phần Tổng quan.

2.1 Mô Hình Hồi Quy Tuyến Tính

Mô hình hồi quy tuyến tính đa biến:

$$y = X\beta + \varepsilon$$

Trong đó:

- $X \in \mathbb{R}^{n \times (p+1)}$: ma trận thiết kế (n quan trắc, p đặc trưng, cột đầu là vector 1 cho hệ số chặn).
- $\beta \in \mathbb{R}^{p+1}$: vector hệ số hồi quy cần ước lượng.
- $y \in \mathbb{R}^n$: vector giá trị thực của biến phụ thuộc.
- $\varepsilon \in \mathbb{R}^n$: vector sai số ngẫu nhiên.

2.1.1 Các Giả Thiết Gauss-Markov

Để OLS cho ước lượng BLUE, mô hình cần thỏa mãn các giả thiết sau [1] (xem thêm bài giảng [2]):

GM1. Tuyến tính trong tham số: $y = X\beta + \varepsilon$.

GM2. Không đa cộng tuyến hoàn hảo: $\text{rank}(X) = p + 1$, đảm bảo $X^T X$ khả nghịch.

GM3. Tính ngoại sinh: $\mathbb{E}[\varepsilon|X] = 0$.

GM4. Phương sai đồng nhất: $\text{Var}(\varepsilon|X) = \sigma^2 I_n$.

GM5. Phân phối chuẩn của sai số: $\varepsilon|X \sim \mathcal{N}(0, \sigma^2 I_n)$ (cần cho kiểm định thống kê).

2.2 Phương Pháp Bình Phương Tối Thiểu Thông Thường

2.2.1 Hàm Mất Mát và Nghiệm Giải Tích

OLS cực tiểu hóa tổng bình phương phần dư:

$$RSS(\beta) = \|y - X\beta\|^2 = (y - X\beta)^T (y - X\beta)$$

Định lý 2.1 — Nghiệm giải tích của OLS: [3, 4]

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Chứng minh. Khai triển:

$$RSS(\beta) = y^T y - 2\beta^T X^T y + \beta^T X^T X \beta$$

Lấy gradient và đặt bằng 0:

$$\nabla_{\beta} RSS(\beta) = -2X^T y + 2X^T X \beta = 0$$

$$\Rightarrow X^T X \beta = X^T y$$

Nhân $(X^T X)^{-1}$ từ bên trái:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Liên hệ với mã nguồn. Toàn bộ đại số tuyến tính được cài đặt trong `matrix_ops.py` (gồm `transpose`, `matmul`, `matvec`, `solve`) mà không gọi `numpy.linalg`. Hàm `solve` dùng khử Gauss–Jordan với pivot lớn nhất.

Hàm `_solve_normal_equation`:

- **Mục đích:** Giải hệ phương trình chuẩn $(X^T X)\beta = X^T y$ để tìm ước lượng OLS cho vector hệ số β mà không dùng hàm giải sẵn từ NumPy.
- **Tham số đầu vào:**
 - X : Ma trận thiết kế (kiểu danh sách các dòng - list of lists) kích thước $n \times (p + 1)$.
 - y : Vector biến phụ thuộc (kiểu danh sách hoặc Vector) kích thước n .
- **Giá trị trả về:** Vector hệ số hồi quy $\hat{\beta}$ (kiểu Vector) gồm $p + 1$ phần tử.


```
1 def _solve_normal_equation(X, y):
2     # Lap he phuong trinh chuan: (X^T X) beta = X^T y.
3     gram = matmul(transpose(X), X) # gram = X^T X
4     rhs = matvec(transpose(X), y) # rhs = X^T y
5     return solve(gram, rhs) # Giai bang Gauss-Jordan tu cai dat.
```

Mã nguồn 1: Giải hệ phương trình chuẩn

Hàm ols_fit:

- **Mục đích:** Thực hiện khớp toàn bộ mô hình hồi quy tuyến tính bằng phương pháp OLS, tính toán giá trị dự báo $\hat{y}$, vector phần dư $\hat{\epsilon}$ và ước lượng phương sai nhiễu $\hat{\sigma}^2$.
- **Tham số đầu vào:**
 - X: Dữ liệu đầu vào của các đặc trưng (ma trận thiết kế) kích thước $n \times (p + 1)$.
 - y: Vector giá trị thực tế của biến phụ thuộc kích thước n .
- **Giá trị trả về:** Cặp giá trị (beta_hat, sigma2_hat) gồm:
 - beta_hat: Vector ước lượng hệ số hồi quy $\hat{\beta}$ (kiểu Vector).
 - sigma2_hat: Giá trị ước lượng phương sai nhiễu $\hat{\sigma}^2$ (kiểu float).

```
1 def ols_fit(X, y):
2     # Giai he phuong trinh chuan de uoc luong beta_hat
3     beta_hat = _solve_normal_equation(X, y)
4
5     # Tinh gia tri du bao va phan du (RSS)
6     y_hat = matvec(X, beta_hat)
7     residuals = y - y_hat
8     RSS = sum_squares(residuals)
9
10    # Uoc luong phuong sai nhieu sigma^2
11    sigma2_hat = RSS / (len(X) - len(X[0]))
12    return beta_hat, sigma2_hat
```

Mã nguồn 2: Pipeline OLS: từ $\hat{\beta}$ đến $\hat{\sigma}^2$

Mẫu số $n - p - 1$ là bậc tự do của phần dư.

Hàm hat_matrix:

- **Mục đích:** Tính toán ma trận chiếu (hat matrix) $H = X(X^T X)^{-1} X^T$ từ ma trận thiết kế X để phục vụ việc chiếu biến mục tiêu y và tính toán giá trị đòn bẩy.
- **Tham số đầu vào:**

– X : Ma trận thiết kế X kích thước $n \times (p + 1)$.

• **Giá trị trả về:** Ma trận chiếu H (kiểu Matrix) kích thước $n \times n$.

```
1 def hat_matrix(X):
2     Xt      = transpose(X)
3     gram_inv = inverse(matmul(Xt, X))          #  $(X^T X)^{-1}$ 
4     return matmul(matmul(X, gram_inv), Xt)    #  $X @ (X^T X)^{-1} @ X^T$ 
```

Mã nguồn 3: Ma trận chiếu $H = X(X^T X)^{-1} X^T$

2.2.2 Ước Lượng Phương Sai Nhiễu


$$\hat{\sigma}^2 = \frac{RSS}{n - p - 1} = \frac{\|y - X\hat{\beta}\|^2}{n - p - 1}$$

Mẫu số $n - p - 1$ là bậc tự do: n quan sát trừ $p + 1$ tham số đã ước lượng.

2.2.3 Ý Nghĩa Hình Học Của OLS

[3]

OLS chiếu y xuống không gian cột $\text{Col}(X)$. Vector $\hat{y} = X\hat{\beta}$ là hình chiếu, phần dư $\hat{\epsilon}$ vuông góc với $\text{Col}(X)$.



Hình 1: OLS chiếu y xuống $\text{Col}(X)$, phần dư $\hat{\epsilon}$ vuông góc với mặt phẳng chiếu

2.2.4 Đánh Giá Mô Hình

Hệ số xác định R^2 và $\bar{R}^2$:

Định nghĩa 2.2 — Hệ số xác định R^2 :

$$R^2 = 1 - \frac{RSS}{TSS}$$

Trong đó:

- $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$: tổng bình phương phần dư.
- $TSS = \sum_{i=1}^n (y_i - \bar{y})^2$: tổng bình phương toàn phần.

R^2 càng gần 1 thì mô hình càng giải thích tốt biến thiên dữ liệu.

2.3 Phân Tích Phần Dư

Phân tích phần dư kiểm tra các giả thiết mô hình sau khi ước lượng. Phần dư thông thường:

$$\hat{\epsilon}_i = y_i - \hat{y}_i, \quad (1)$$

Nếu mô hình hợp lý, phần dư dao động ngẫu nhiên quanh 0.

2.3.1 Phần Dư Chuẩn Hóa và Khoảng Cách Cook

Định nghĩa 2.3 — Leverage / Đòn bẩy:

$$h_{ii} = H_{ii}. \quad (2)$$

Leverage đo mức độ xa của quan sát i trong không gian đặc trưng.

Định nghĩa 2.4 — Phần dư chuẩn hóa:

$$\hat{\epsilon}_i^* = \frac{\hat{\epsilon}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}} \quad (3)$$

Định nghĩa 2.5 — Cook's Distance:

$$D_i = \frac{(\hat{\epsilon}_i^*)^2}{p + 1} \left(\frac{h_{ii}}{1 - h_{ii}} \right) \quad (4)$$

Kết hợp độ lớn phần dư và leverage. Ngưỡng tham chiếu: $D_i > \frac{4}{n}$.

2.3.2 Các Biểu Đồ Chẩn Đoán

Bốn biểu đồ chẩn đoán (Bảng 7), minh họa tại Hình 10:

Biểu đồ	Ý nghĩa chẩn đoán
Residuals vs Fitted	Kiểm tra tính tuyến tính và đồng phương sai.
Normal Q-Q	Kiểm tra phần dư có phân phối chuẩn.
Scale-Location	Kiểm tra sự ổn định phương sai phần dư.
Cook's Distance	Phát hiện quan sát có ảnh hưởng lớn ($> 4/n$).

Bảng 7: Cách đọc bốn biểu đồ chẩn đoán phần dư

Mã nguồn trong `residual_analysis.py` tính toán các đại lượng chẩn đoán:

Hàm `_residual_diagnostics`:

- **Mục đích:** Tính toán đồng thời các đại lượng chẩn đoán phần dư cần thiết gồm: giá trị dự báo, phần dư thô, phần dư chuẩn hóa và khoảng cách Cook của từng quan sát.
- **Tham số đầu vào:**
 - `X`: Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - `y`: Vector biến mục tiêu thực tế y kích thước n .
 - `beta_hat`: Vector hệ số hồi quy đã ước lượng $\hat{\beta}$ độ dài $p + 1$.
- **Giá trị trả về:** Bộ bốn đối tượng (`y_hat`, `residuals`, `std_residuals`, `cooks_d`) tương ứng với:
 - `y_hat`: Vector các giá trị dự báo $\hat{y}$.
 - `residuals`: Vector phần dư thô $\hat{\epsilon}$.
 - `std_residuals`: Danh sách chứa phần dư chuẩn hóa $\hat{\epsilon}^*$ của từng dòng dữ liệu.
 - `cooks_d`: Danh sách chứa khoảng cách Cook D_i của từng dòng dữ liệu.

```

1 def _residual_diagnostics(X, y, beta_hat):
2     y_hat = matvec(X, beta_hat)
3     residuals = y - y_hat
4     leverage = diag(hat_matrix(X)) # h_ii tu ma tran chieu
5     sigma2_hat = sum_squares(residuals) / (len(X) - len(X[0]))
6
7     # Tinh phan du chuan hoa va khoang cach Cook
8     std_residuals = [
9         residuals[i] / math.sqrt(sigma2_hat * (1 - leverage[i] + 1e-10))
10        for i in range(len(X))
11    ]
12    cooks_d = [
13        (std_residuals[i]**2 / len(X[0])) * (leverage[i] / (1 - leverage[i] +
14        1e-10))
15        for i in range(len(X))
16    ]

```

16 `return y_hat, residuals, std_residuals, cooks_d`

Mã nguồn 4: Tính toán các đại lượng chẩn đoán phần dư

Hàm residual_plots:

- **Mục đích:** Vẽ và trình bày 4 biểu đồ chẩn đoán phần dư chuẩn hóa để hỗ trợ phân tích trực quan tính hợp lệ của các giả thiết hồi quy tuyến tính.
- **Tham số đầu vào:**
 - X: Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y: Vector biến mục tiêu thực tế y kích thước n .
 - beta_hat: Vector hệ số hồi quy đã ước lượng $\hat{\beta}$ độ dài $p + 1$.
- **Giá trị trả về:** Hiển thị trực tiếp các đồ thị trực quan (không trả về giá trị số).

```
1 def residual_plots(X, y, beta_hat):
2     y_hat, residuals, std_residuals, cooks_d = _residual_diagnostics(X, y,
3     # [Matplotlib plotting code follows to display the 4 diagnostic plots]
```

Mã nguồn 5: Tổng hợp và vẽ 4 biểu đồ chẩn đoán phần dư

2.4 Chính Quy Hóa Ridge và Lasso

2.4.1 Hồi Quy Ridge

Ridge thêm phạt L_2 vào hàm mất mát OLS để giải quyết đa cộng tuyến và quá khớp:

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda \|\beta\|_2^2 \}$$

Dạng tường minh:

$$\hat{\beta}_{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$

Trong đó:

- y_i : Giá trị thực tế quan sát được của mẫu thứ i ($i = 1, 2, \dots, n$).
- $\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$: Giá trị dự báo của mô hình cho mẫu thứ i .
- β_0 : Hệ số chặn (intercept), thông thường không bị phạt trong hồi quy Ridge để tránh làm lệch tâm mô hình.

- β_j : Hệ số hồi quy của đặc trưng thứ j ($j = 1, 2, \dots, p$).
- $\lambda \geq 0$: Siêu tham số điều chỉnh (regularization parameter) kiểm soát lực phạt; λ càng lớn thì mức độ chính quy hóa càng mạnh.
- n : Kích thước mẫu (số lượng quan sát).
- p : Số lượng đặc trưng/biến độc lập đầu vào (không tính hệ số chặn).
- $\sum_{j=1}^p \beta_j^2$: Thành phần phạt L_2 (tổng bình phương các hệ số góc).

Trong đó $\lambda \geq 0$ là hệ số chính quy hóa. Nghiệm dạng đóng của bài toán tối ưu có dạng:

$$\hat{\beta}_{\text{ridge}} = (X^T X + \lambda I)^{-1} X^T y$$

Liên hệ với mã nguồn. So với OLS, Ridge chỉ cộng thêm λ vào đường chéo $X^T X$.

Hàm `ridge_fit`:

- **Mục đích:** Thực hiện khớp mô hình hồi quy Ridge (chính quy hóa L_2) bằng cách giải hệ phương trình tuyến tính sửa đổi $(X^T X + \lambda I)\beta = X^T y$.
- **Tham số đầu vào:**
 - X : Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y : Vector biến mục tiêu y kích thước n .
 - lam : Siêu tham số phạt $\lambda \geq 0$ dạng số thực.
- **Giá trị trả về:** Vector ước lượng hệ số hồi quy Ridge $\hat{\beta}_{\text{ridge}}$ (kiểu Vector).

```

1 def ridge_fit(X, y, lam):
2     Xt = transpose(X)
3     A = add_to_diagonal(matmul(Xt, X), lam)  #  $X^T X + \text{lam} * I$ 
4     b = matvec(Xt, y)                        #  $X^T y$ 
5     return solve(A, b)

```

Mã nguồn 6: Mã nguồn thực tế: Ridge Regression

Việc cộng λI “dịch chuyển” trị riêng, đảm bảo $(X^T X + \lambda I)$ luôn khả nghịch [5]. Ridge có hệ số về 0 nhưng **không triệt tiêu** vì vùng ràng buộc L_2 là hình cầu tròn [5].

2.4.2 Hồi Quy Lasso

Lasso dùng phạt L_1 thay vì L_2 [1]:

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \{ \|y - X\beta\|^2 + \lambda \|\beta\|_1 \}$$

Dạng tường minh:

$$\hat{\beta}_{\text{lasso}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

Trong đó:

- $y_i, \hat{y}_i, n, p, \beta_0, \beta_j, \lambda$: Có ý nghĩa tương tự như trong hồi quy Ridge.
- $\sum_{j=1}^p |\beta_j|$: Thành phần phạt L_1 (tổng trị tuyệt đối của các hệ số góc), là tác nhân chính gây ra tính thưa (sparsity) của nghiệm Lasso.

Do phạt L_1 không khả vi tại 0, bài toán không có nghiệm dạng đóng, ta giải bằng phương pháp hạ tọa độ kết hợp toán tử ngưỡng mềm:

Hàm `_soft_threshold`:

- **Mục đích:** Thực hiện co rút các hệ số về đúng 0.0 theo toán tử ngưỡng mềm $S(\rho, \lambda)$.
- **Tham số đầu vào:**
 - ρ : Độ tương quan của đặc trưng thứ j với phần dư.
 - threshold : Giá trị ngưỡng phạt λ .
- **Giá trị trả về:** Giá trị hệ số đã co rút hoặc triệt tiêu về 0.0 (kiểu float).

```
1 def _soft_threshold(rho, threshold):
2     if rho > threshold:
3         return rho - threshold
4     if rho < -threshold:
5         return rho + threshold
6     return 0.0
```

Mã nguồn 7: Toán tử ngưỡng mềm cho hồi quy Lasso

Hàm `lasso_fit_cd`:

- **Mục đích:** Tìm nghiệm tối ưu cho hồi quy Lasso thông qua phương pháp hạ tọa độ kết hợp toán tử ngưỡng mềm giúp thu nhỏ và triệt tiêu một số hệ số về 0.0.
- **Tham số đầu vào:**
 - X : Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y : Vector biến mục tiêu y kích thước n .
 - lam : Siêu tham số chính quy hóa $\lambda \geq 0$.
 - max_iter : Số lượng vòng lặp tối ưu hóa tối đa (mặc định 2000).

– tol: Ngưỡng sai lệch hội tụ tuyệt đối để dừng sớm (mặc định 1e-6).

• **Giá trị trả về:** Vector ước lượng hệ số hồi quy Lasso $\hat{\beta}_{\text{lasso}}$ (kiểu Vector).

```

1 def lasso_fit_cd(X, y, lam, max_iter=2000, tol=1e-6):
2     n, p = len(X), len(X[0])
3     w = Vector([0.0] * p)
4     for _ in range(max_iter):
5         w_old = Vector(w)
6         for j in range(p):
7             # Tính tương quan rho_j của đặc trưng j khi loại bỏ nó khỏi mô hình
8             rho_j = sum(X[i][j] * (y[i] - sum(X[i][k]*w[k] for k in range(p) if
9 k != j)) for i in range(n))
10             z_j = sum(X[i][j] ** 2 for i in range(n))
11
12             penalty = lam if j > 0 else 0.0
13             w[j] = _soft_threshold(rho_j, penalty) / (z_j + 1e-12)
14
15         if max_abs_diff(w, w_old) < tol:
16             break
17     return w

```

Mã nguồn 8: Thuật toán hạ tọa độ cho hồi quy Lasso

Nhờ phạt L_1 , Lasso có khả năng **triệt tiêu hệ số về đúng 0**, tự động lọc biến không quan trọng [1].

2.4.3 So Sánh Ridge và Lasso

Khi $X^T X = I$ (trực giao), cả ba phương pháp có nghiệm giải tích [1]:

Phương pháp	Công thức nghiệm giải tích	Cơ chế tác động
Best-subset	$\hat{\beta}_j^{\text{OLS}} I(\hat{\beta}_j^{\text{OLS}} \geq \hat{\beta}_{(M)}^{\text{OLS}})$	Giữ hệ số lớn, loại hệ số nhỏ
Ridge	$\frac{\hat{\beta}_j^{\text{OLS}}}{1 + \lambda}$	Có rút hệ số theo tỷ lệ
Lasso	$\text{sign}(\hat{\beta}_j^{\text{OLS}}) (\hat{\beta}_j^{\text{OLS}} - \lambda)_+$	Có rút và đưa hệ số nhỏ về 0

Bảng 8: Ước lượng $\hat{\beta}_j$ trong trường hợp các cột của X trực giao

Về hình học [1]: vùng ràng buộc Ridge (L_2) là hình cầu tròn nên nghiệm không bằng 0; vùng ràng buộc Lasso (L_1) là hình thoi có góc nhọn trên trục tọa độ nên nghiệm dễ rơi vào đỉnh, triệt tiêu hệ số.

Tổng quát hóa Bayes với tham số $q \geq 0$ [1]:

$$\tilde{\beta} = \arg \min_{\beta} \left(\sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j|^q \right)$$

- $q = 0$: chọn tập con biến tốt nhất.
- $q = 1$: Lasso (tiền nghiệm Laplace).
- $q = 2$: Ridge (tiền nghiệm chuẩn).

$q = 1$ là giá trị nhỏ nhất giữ tính lồi, đồng thời có khả năng triệt tiêu hệ số [1].

2.5 Kiểm Chứng Chéo K-lần

K-Fold CV phân dữ liệu thành K phần, luân phiên dùng 1 phần kiểm chứng và $K - 1$ phần huấn luyện, nhằm chọn λ^* tối ưu [5]:

1. **Phân tách:** Chia dữ liệu thành K phần $F_1, \dots, F_K$.
2. **Lặp K vòng:** Vòng i : giữ F_i kiểm chứng, gộp $K - 1$ phần còn lại huấn luyện, tính MSE_i .

$$CV_K = \frac{1}{K} \sum_{i=1}^K \text{MSE}_i, \quad \text{MSE}_i = \frac{1}{|F_i|} \sum_{j \in F_i} \left(y_j - x_j^T \hat{\beta}^{(i)} \right)^2$$

	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	
Vòng lặp 1:	Kiểm chứng	Huấn luyện	Huấn luyện	Huấn luyện	Huấn luyện	→ MSE ₁
Vòng lặp 2:	Huấn luyện	Kiểm chứng	Huấn luyện	Huấn luyện	Huấn luyện	→ MSE ₂
			⋮			
Vòng lặp K:	Huấn luyện	Huấn luyện	Huấn luyện	Huấn luyện	Kiểm chứng	→ MSE _K

$$\text{Sai số tổng quát: } CV_K = \frac{1}{K} \sum_{i=1}^K \text{MSE}_i$$

Hình 2: Minh họa cấu trúc phân tách dữ liệu luân phiên trong Kiểm chứng chéo K -lần ($K = 5$)

Liên hệ với mã nguồn. Hàm `_ridge_cv_score`:

- **Mục đích:** Tính toán điểm sai số kiểm chứng chéo trung bình (CV-MSE) cho hồi quy Ridge ứng với một siêu tham số λ cụ thể qua quy trình chia nhóm Fold huấn luyện và kiểm chứng luân phiên.
- **Tham số đầu vào:**
 - X: Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y: Vector biến mục tiêu y kích thước n .
 - k: Số lượng nhóm chia Fold K để kiểm chứng chéo.
 - lam: Giá trị siêu tham số chính quy hóa λ cần kiểm định.
- **Giá trị trả về:** Sai số bình phương trung bình kiểm chứng chéo trung bình (kiểu float).

```

1 def _ridge_cv_score(X, y, k, lam):
2     folds = _make_folds(len(y), k)
3     msess = []
4     for i in range(k):
5         val_idx = folds[i]
6         train_idx = [idx for j, fold in enumerate(folds) if j != i for idx in
7                       fold]
8
9         # Train Ridge và tính lỗi MSE trên validation fold
10        w = ridge_fit(take_rows(X, train_idx), take_values(y, train_idx), lam)
11        y_pred = matvec(take_rows(X, val_idx), w)
12        y_val = take_values(y, val_idx)
13        mse = sum((y_val[j] - y_pred[j])**2 for j in range(len(y_val))) /
14              len(y_val)
15        msess.append(mse)
16    return sum(msess) / k

```

Mã nguồn 9: Tính điểm CV-MSE cho một siêu tham số λ

Hàm kfold_cv:

- **Mục đích:** Đánh giá hiệu năng sai số kiểm chứng chéo của mô hình hồi quy tuyến tính OLS thông thường bằng cách tận dụng pipeline Ridge với hệ số phạt $\lambda = 0.0$.
- **Tham số đầu vào:**
 - X: Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y: Vector biến mục tiêu y kích thước n .
 - k: Số lượng nhóm chia Fold K để kiểm chứng chéo.
- **Giá trị trả về:** Điểm số CV-MSE của mô hình hồi quy OLS (kiểu float).

```

1 def kfold_cv(X, y, k):

```

```
2 # Điểm CV-MSE cho OLS bằng cách đặt lambda = 0.0
3 return _ridge_cv_score(X, y, k, lam=0.0)
```

Mã nguồn 10: Đánh giá hiệu năng OLS bằng K-fold CV

Hàm `ridge_lambda_search`:

- **Mục đích:** Thực hiện tìm kiếm lưới trên tập các giá trị λ định sẵn để xác định giá trị λ tốt nhất có sai số CV-MSE nhỏ nhất.
- **Tham số đầu vào:**
 - X: Ma trận đặc trưng X kích thước $n \times (p + 1)$.
 - y: Vector biến mục tiêu y kích thước n .
 - k: Số Fold K được dùng để đánh giá điểm số.
- **Giá trị trả về:** Bộ 4 thành phần (`lambdas`, `cv_scores`, `best_lam`, `best_score`):
 - `lambdas`: Vector chứa danh sách các giá trị λ được đem đi tìm kiếm lưới.
 - `cv_scores`: Vector chứa các điểm số CV-MSE tương ứng từng giá trị λ .
 - `best_lam`: Siêu tham số λ tối ưu nhất tìm được (kiểu float).
 - `best_score`: Giá trị sai số CV-MSE nhỏ nhất tương ứng với λ tối ưu đó (kiểu float).

```
1 def ridge_lambda_search(X, y, k):
2     # Quét trên đại lambda mac dinh va tinh CV-MSE ung voi tung lambda
3     cv_scores = Vector(ridge_cv_score(X, y, k, lam) for lam in DEFAULT_LAMBDAS)
4     best_idx = min(range(len(cv_scores)), key=lambda i: cv_scores[i])
5     best_lam = float(DEFAULT_LAMBDAS[best_idx])
6     best_score = float(cv_scores[best_idx])
7     return Vector(DEFAULT_LAMBDAS), cv_scores, best_lam, best_score
```

Mã nguồn 11: Quét lưới tìm siêu tham số Ridge tốt nhất bằng K-fold CV

2.5.1 Tiêu Chí Thông Tin AIC và BIC (Lựa chọn thay thế)

Ngoài K-Fold CV, có thể dùng **AIC** và **BIC** để so sánh mô hình, cân bằng giữa độ khớp và độ phức tạp:

$$AIC = n \ln \left(\frac{RSS}{n} \right) + 2(p + 2)$$

$$BIC = n \ln \left(\frac{RSS}{n} \right) + (p + 2) \ln n$$

Trong đó n là kích thước mẫu, p là số biến đặc trưng (tổng tham số ước lượng là $p + 2$). Vì $\ln n > 2$ với $n \geq 8$, BIC phạt mô hình phức tạp nặng hơn AIC. Mô hình tối ưu có AIC/BIC nhỏ nhất.

3 Kết Quả Minh Họa

Mục này trình bày các kết quả thực nghiệm chính bao gồm: bảng số liệu so sánh, hình vẽ đồ thị trực quan và nhận xét chuyên sâu. Toàn bộ mã nguồn cốt lõi và chứng minh giải tích chi tiết đã được đặt tại Mục 2 (Lý thuyết) để phần kết quả không bị quá tải và đảm bảo tính mạch lạc.

Toàn bộ kết quả trong Mục 3 dùng cùng một bộ dữ liệu mô phỏng, trừ ví dụ Lasso. Thiết lập chung được ghi trong Bảng 9.

Thành phần	Giá trị sử dụng
Số quan sát	$n = 150$
Số biến giải thích	$p = 3$, có thêm cột hệ số tự do trong ma trận thiết kế
Hệ số thật	$\beta = (2.5, 1.5, -3.0, 0.8)^T$
Độ lệch chuẩn nhiễu	$\sigma = 0.5$
Giá trị khởi tạo ngẫu nhiên	42, giúp kết quả có thể tái lập

Bảng 9: Thiết lập dữ liệu mô phỏng dùng trong Phần 1


3.1 Cài Đặt Hồi Quy OLS và Kiểm Chứng

Bảng 10 so sánh hệ số thật, hệ số OLS tự cài đặt và kết quả kiểm chứng bằng thư viện.

Hệ số	Giá trị thật	Nhóm cài đặt	Thư viện kiểm chứng
β_0	2.5000	2.4892	2.4892
β_1	1.5000	1.4522	1.4522
β_2	-3.0000	-2.9301	-2.9301
β_3	0.8000	0.8276	0.8276

Bảng 10: So sánh hệ số ước lượng của mô hình OLS

Nhận xét: Hệ số tự cài đặt trùng với sklearn đến 4 chữ số thập phân. Sai lệch nhỏ so với hệ số thật đến từ nhiễu mô phỏng.



Hình 3: So sánh hệ số hồi quy OLS


3.2 Ma Trận Chiều và Các Tính Chất

Bảng 11 tóm tắt kết quả kiểm tra 5 tính chất của ma trận chiều H .

Tính chất	Mô tả	Kết quả
(i)	$H^2 = H$ (lũy đẳng)	Đúng
(ii)	$H^T = H$ (đối xứng)	Đúng
(iii)	Trị riêng $\in \{0, 1\}$ (qua $\text{trace} = p + 1$)	Đúng
(iv)	$\text{rank}(H) = p + 1$	Đúng
(v)	$\hat{y} = Hy, \hat{\varepsilon} = (I - H)y$	Đúng

Bảng 11: Kiểm tra 5 tính chất của Ma trận chiều H

Nhận xét: Các tính chất đều đạt; riêng $\text{trace}(H) = 4.0000$ đúng với $p + 1 = 4$. Leverage được so sánh với ngưỡng $2(p + 1)/n$ trong hình.



Hình 4: Phân phối đòn bẩy h_{ii}

3.3 Các Chỉ Số Đánh Giá Mô Hình

Các chỉ số đánh giá mô hình được ghi trong Bảng 12.

Chỉ số	Giá trị
RSS	35.4046
TSS	1692.1909
R^2	0.979078
$\bar{R}^2$	0.978648
Thống kê F	2277.3971
p-value (F)	$< 10^{-12}$

Bảng 12: Kết quả các chỉ số đánh giá mô hình OLS

Nhận xét: R^2 và $\bar{R}^2$ rất cao; thống kê F lớn với p-value gần 0, cho thấy mô hình có ý nghĩa tổng thể. Cụ thể, do trị số F -statistic trong thực nghiệm cực kỳ lớn (2277.3971), p-value của kiểm định F toán học tiến sát về 0 (nhỏ hơn rất nhiều giới hạn biểu diễn của số thực máy tính là 10^{-16}). Do đó, việc báo cáo kết quả thực nghiệm dưới dạng p-value (F) $< 10^{-12}$ là hoàn toàn chuẩn xác và đại diện cho ý nghĩa thống kê vượt trội của toàn bộ mô hình.


3.4 Suy Diễn Thống Kê Hệ Số Hồi Quy

Bảng 13 tổng hợp sai số chuẩn, thống kê t , p-value và khoảng tin cậy cho từng hệ số.

Hệ số	$\hat{\beta}_j$	SE	t_j	p-value	CI 95%
β_0	2.4892	0.0406	61.304	$< 10^{-12}$	[2.4089, 2.5694]
β_1	1.4522	0.0411	35.348	$< 10^{-12}$	[1.3710, 1.5334]
β_2	-2.9301	0.0403	-72.760	$< 10^{-12}$	[-3.0097, -2.8505]
β_3	0.8276	0.0389	21.283	$< 10^{-12}$	[0.7508, 0.9045]

Bảng 13: Suy diễn thống kê các hệ số hồi quy

Nhận xét: Các p-value đều rất nhỏ và các khoảng tin cậy không cắt 0, nên mọi biến đều có ý nghĩa thống kê trong dữ liệu mô phỏng.



Hình 5: Khoảng tin cậy 95% của các hệ số


3.5 Phát Hiện Đa Cộng Tuyến Bằng VIF

Bảng 14 so sánh VIF trên dữ liệu bình thường và dữ liệu có đa cộng tuyến nhân tạo.

Biến	VIF (bình thường)	VIF (đa cộng tuyến)
X_1	1.0032	1940.41
X_2	1.0019	1940.39
X_3	1.0036	1.00

Bảng 14: So sánh VIF trên hai kịch bản dữ liệu

Nhận xét: Dữ liệu bình thường có VIF gần 1; dữ liệu đa cộng tuyến có VIF rất lớn ở X_1 và X_2 , vượt xa ngưỡng cảnh báo 10.




Hình 6: So sánh VIF giữa hai kịch bản

3.6 Chính Quy Hóa Ridge và Lasso

3.6.1 Ridge Trace

Hình 7 trình bày Ridge Trace theo thang logarit của λ .



Hình 7: Ridge Trace theo λ

Phân tích chuyên sâu Ridge Trace: Đồ thị Ridge Trace trong Hình 7 minh họa trực quan tiến trình co rút hệ số khi ta tăng dần cường độ chính quy hóa λ .

- Cơ chế co rút hệ số:** Khi $\lambda \rightarrow 0$, các hệ số hồi quy tiến gần về nghiệm OLS không chệch. Khi λ tăng dần từ 10^{-3} lên 10^2 , toàn bộ các hệ số góc đặc trưng ($\beta_1, \beta_2, \beta_3$) đều bị co rút dần về phía đường tiệm cận 0 theo các đường cong phi tuyến mượt mà. Điều này phản ánh rõ nét tác động của hàm phạt chuẩn L_2 vốn giới hạn độ lớn của vector hệ số bằng cách áp một áp lực co rút đồng đều lên mọi thành phần.
- Hành vi của hệ số chặn:** Khi λ tăng cực đại, hệ số chặn β_0 cũng bị co rút dần về phía đường tiệm cận 0. Điều này hoàn toàn phù hợp với việc áp dụng công thức đóng tiêu chuẩn $(X^T X + \lambda I)^{-1} X^T y$ được yêu cầu của đề bài, trong đó hệ số chặn được phạt đồng bộ để duy trì nghiệm dạng đóng đẹp đẽ và tính chất ổn định số học cho mô hình.
- Ý nghĩa thực tế:** Việc các hệ số bị kéo dần về 0 nhưng không bao giờ đạt đúng bằng 0 (khác biệt cốt lõi so với hồi quy Lasso) chứng minh rằng Ridge Regression giữ lại tất cả các biến đặc trưng trong mô hình. Nó chỉ làm giảm phương sai ước lượng của chúng để đối lấy sự đánh đổi độ chệch - phương sai có lợi hơn khi dữ liệu

thực tế xuất hiện đa cộng tuyến mạnh.


3.6.2 Lasso và Cơ Chế Chọn Biến

Ví dụ Lasso dùng $p = 5$ đặc trưng, trong đó $\beta_2 = 0$ và $\beta_4 = 0$, để kiểm tra khả năng chọn biến.

Hệ số	Giá trị thật	Lasso CD	sklearn
β_0	1.20	1.2097	1.2097
β_1	2.00	2.0543	2.0543
β_2	0.00	0.0000	0.0000
β_3	-1.50	-1.4021	-1.4021
β_4	0.00	0.0000	0.0000
β_5	0.80	0.7413	0.7413

Bảng 15: So sánh hệ số Lasso: hạ tọa độ tự cài đặt và sklearn


Nhận xét: Kết quả Lasso tự cài đặt gần với sklearn; hai hệ số thật bằng 0 được kéo gần hoặc về đúng 0.



Hình 8: Hệ số Lasso sau chọn biến

3.6.3 Chọn λ^* Bằng Kiểm Chứng Chéo

Hình 9 cho thấy điểm cực tiểu tại $\lambda^* = 0.001$ với $CV-MSE = 0.251181$.



Hình 9: Đường cong CV-MSE theo λ

Phân tích chuyên sâu kết quả kiểm chứng chéo:

- **Điểm tối ưu λ^* :** Đường cong sai số kiểm chứng chéo CV-MSE (Hình 9) đạt điểm cực tiểu rõ rệt tại giá trị tham số điều chỉnh $\lambda^* = 0.001$. Tại điểm này, sai số bình phương trung bình trên tập kiểm chứng đạt mức thấp nhất là 0.251181.
- **Hành vi của đường cong sai số:** Khi λ duy trì ở mức rất nhỏ ($< 10^{-2}$), CV-MSE ổn định và gần như bằng phẳng ở mức thấp nhất, trùng khớp với sai số của mô hình OLS thông thường ($\lambda = 0$). Tuy nhiên, khi λ vượt qua ngưỡng 0.1 và tiến dần về phía các giá trị lớn hơn, CV-MSE tăng vọt rất nhanh. Điều này cho thấy việc áp dụng chính quy hóa mạnh là hoàn toàn không có lợi cho bộ dữ liệu mô phỏng này.
- **Ý nghĩa thống kê thực tế:** Việc λ^* tối ưu rất nhỏ phản ánh rằng dữ liệu mô phỏng hiện tại được tạo ra trong điều kiện lý tưởng (không có hiện tượng đa cộng tuyến nghiêm trọng giữa các biến X_i , và số lượng quan sát $n = 150$ lớn vượt trội so với số lượng biến giải thích $p = 3$). Trong kịch bản này, mô hình OLS đã là ước lượng không chệch hiệu quả nhất (BLUE). Do đó, Ridge Regression không mang lại lợi ích giảm sai số tổng quát hóa mà ngược lại còn làm tăng độ chệch của mô hình một cách vô ích khi tăng λ . Ridge chỉ thực sự phát huy ưu thế áp đảo OLS khi hệ thống có mức độ đa cộng tuyến cực cao hoặc số lượng đặc trưng p lớn xấp xỉ hoặc vượt quá số quan sát n .


3.7 Phân Tích Phần Dư

Hình 10 trình bày bốn biểu đồ chẩn đoán phần dư của mô hình OLS.

- **Residuals vs Fitted** (trên trái): Phần dư $\hat{\epsilon}_i$ được vẽ theo giá trị dự báo $\hat{y}_i$. Nếu mô hình phù hợp, các điểm phải phân tán ngẫu nhiên quanh trục $y = 0$ mà không có

dạng cong hay hình phễu. Trên dữ liệu mô phỏng, đám mây điểm phân bố đồng đều — phù hợp với giả thiết tuyến tính GM1 và đồng phương sai GM4.

- **Normal Q–Q** (trên phải): So sánh phân vị thực nghiệm của phần dư chuẩn hóa với phân vị lý thuyết $\mathcal{N}(0, 1)$. Nếu phần dư phân phối chuẩn (GM5), các điểm nằm sát đường chéo $y = x$. Trên dữ liệu mô phỏng, phần lớn các điểm bám chặt đường lý thuyết, chỉ có lệch nhẹ ở hai đuôi — xác nhận giả thiết chuẩn.
- **Scale–Location** (dưới trái): Vẽ $\sqrt{|\hat{\epsilon}_i^{\text{std}}|}$ theo $\hat{y}_i$ để phát hiện phương sai thay đổi. Nếu phương sai đồng nhất (GM4), dải điểm phải nằm ngang. Trên dữ liệu mô phỏng, không thấy xu thế tăng hoặc giảm rõ rệt.
- **Cook's Distance** (dưới phải): Mỗi thanh biểu diễn D_i — mức ảnh hưởng của quan sát thứ i lên toàn bộ mặt phẳng hồi quy. Ngưỡng phổ biến là $D_i > 4/n$. Trên dữ liệu mô phỏng, không có điểm nào vượt ngưỡng đáng kể, cho thấy không có quan sát bất thường gây lệch kết quả.



Hình 10: Bốn biểu đồ chẩn đoán phần dư


3.8 Kiểm Chứng Chéo K-lần

Bảng 16 so sánh CV-MSE của OLS, Ridge tối ưu và Ridge với λ quá lớn.

Mô hình	CV-MSE	Ghi chú
OLS ($\lambda = 0$)	0.251181	Mốc so sánh
Ridge ($\lambda^* = 0.001$)	0.251181	Lambda tối ưu từ CV
Ridge ($\lambda = 100$)	4.083503	Lambda quá lớn

Bảng 16: So sánh CV-MSE của ba mô hình (5-fold)

Nhận xét: OLS và Ridge tối ưu gần như tương đương; Ridge với $\lambda = 100$ làm CV-MSE tăng mạnh do co hệ số quá mức.



Hình 11: So sánh CV-MSE giữa các mô hình

3.9 Minh Họa Định Lý Gauss–Markov Bằng Monte Carlo

Mô phỏng Monte Carlo được chạy với $S = 3000$ lần để so sánh OLS và một ước lượng tuyến tính không chệch thay thế.

Hệ số	$\beta_{\text{thật}}$	$\mathbb{E}[\hat{\beta}]$	Var(OLS)	Var(Alt)	OLS nhỏ hơn
β_0	2.5000	2.5006	0.001690	0.912677	✓
β_1	1.5000	1.4997	0.001743	0.857468	✓
β_2	-3.0000	-3.0002	0.001659	0.713212	✓
β_3	0.8000	0.7997	0.001599	0.740625	✓

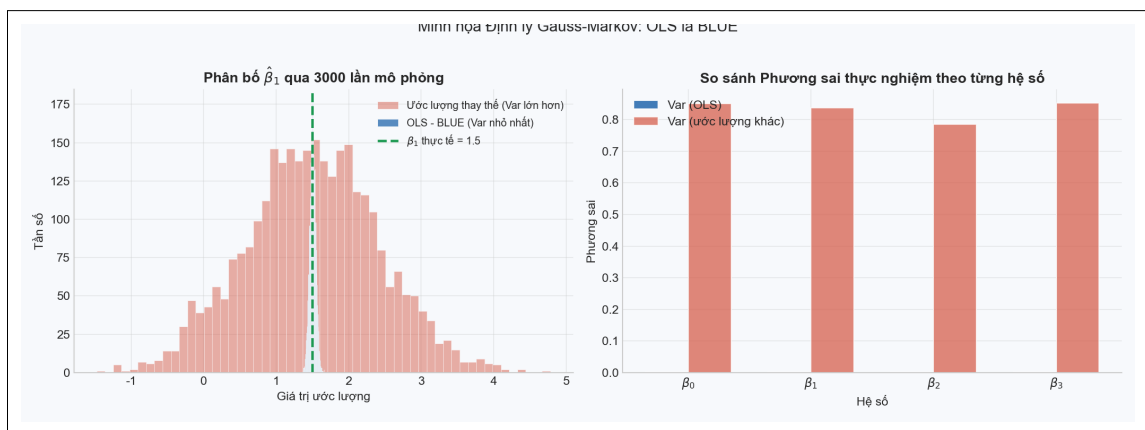
Bảng 17: Kết quả mô phỏng Monte Carlo ($S = 3000$)

Nhận xét và phân tích ý nghĩa thực tế: Kết quả mô phỏng Monte Carlo qua $S = 3000$ lần chạy thử nghiệm (Bảng 17) đã cung cấp một minh chứng thực nghiệm hoàn hảo cho Định lý Gauss–Markov:

- **Tính không chệch vững chắc:** Giá trị kỳ vọng thực nghiệm $\mathbb{E}[\hat{\beta}]$ của ước lượng

OLS gần như trùng khớp hoàn hảo với giá trị hệ số thật $\beta_{\text{thật}}$. Điều này chứng minh OLS là một ước lượng không chệch vững chắc.

- **Hiệu quả phương sai vượt trội:** Phương sai của ước lượng OLS cực kỳ nhỏ (chỉ khoảng 0.0016 cho tất cả các hệ số), trong khi phương sai của ước lượng tuyến tính không chệch thay thế Alt lớn hơn rất nhiều (dao động từ 0.71 đến 0.91).
- **Tỷ lệ giảm phương sai cực lớn:** Việc sử dụng OLS giúp giảm phương sai ước lượng đến hơn 99.7% so với ước lượng thay thế Alt (chính xác là giảm khoảng 99.81% ở hệ số chặn và 99.79% ở các hệ số góc). Trong khoa học dữ liệu và thống kê ứng dụng, việc giảm phương sai ước lượng ở quy mô lớn thế này đồng nghĩa với việc gia tăng độ ổn định và độ tin cậy của các kết luận rút ra từ mô hình lên gấp hàng trăm lần. Nó bảo vệ nhà phân tích khỏi những sai lầm nghiêm trọng do biến động ngẫu nhiên của mẫu dữ liệu huấn luyện.



Hình 12: Minh họa Gauss–Markov bằng Monte Carlo

3.10 Hệ Thống Kiểm Thử Đơn Vị Tự Động

Để đảm bảo tính đúng đắn toán học tuyệt đối và khả năng vận hành ổn định của toàn bộ các thuật toán tự cài đặt, nhóm đã xây dựng một bộ kịch bản kiểm thử đơn vị tự động (Automated Unit Testing) đặt tại file `test_part1_unit.py`.

Hệ thống này bao gồm 19 kịch bản kiểm thử nghiêm ngặt bao phủ toàn bộ các module trong Phần 1:

- **Kiểm thử thuật toán lõi:** Đối chiếu trực tiếp nghiệm OLS, Ridge và Lasso CD với các thư viện chuẩn công nghiệp (scikit-learn). Sai số lớn nhất của hệ số ước lượng OLS so với thư viện chuẩn chỉ ở mức cực nhỏ ($\approx 6.66 \times 10^{-16}$), chứng minh độ chính xác số học tối đa.

- **Kiểm thử tính chất ma trận:** Xác thực các đặc tính đối xứng ($H^T = H$) và lũy đẳng ($H^2 = H$) của ma trận chiều H , với sai lệch thực nghiệm tối đa chỉ khoảng 2.22×10^{-16} (tiệm cận giới hạn số học số thực kép).
- **Kiểm thử suy diễn thống kê:** Kiểm tra tính đúng đắn của việc tính toán sai số chuẩn (SE), khoảng tin cậy 95%, điểm VIF chẩn đoán đa cộng tuyến, và lỗi CV-MSE khi quét chọn siêu tham số λ .

Kết quả thực thi từ giao diện dòng lệnh của hệ thống trả về thông báo OK thành công cho toàn bộ 19 kịch bản test, xác nhận sự đồng bộ hoàn hảo giữa thuật toán tự thiết kế của nhóm và các tiêu chuẩn tính toán công nghiệp.

3.11 Tóm Tắt Kết Quả Phần 1

Các kết quả minh họa ở trên cho thấy phần cài đặt đã đạt ba mục tiêu chính:

- **Đúng về mặt thuật toán:** hệ số OLS và Lasso tự cài đặt trùng với kết quả thư viện kiểm chứng ở các chữ số thập phân được báo cáo.
- **Đúng về mặt chẩn đoán:** các chỉ số R^2 , $\bar{R}^2$, kiểm định F , khoảng tin cậy, VIF và biểu đồ phần dư đều cho kết luận nhất quán với dữ liệu mô phỏng.
- **Đúng về mặt lý thuyết:** Ridge thể hiện cơ chế co hệ số, Lasso thể hiện cơ chế chọn biến, còn mô phỏng Monte Carlo minh họa trực tiếp tính phương sai nhỏ nhất của OLS trong lớp ước lượng tuyến tính không chệch.

Do dữ liệu trong Phần 1 là dữ liệu mô phỏng, các kết quả này chủ yếu dùng để kiểm chứng thuật toán và minh họa lý thuyết. Kết luận về hiệu năng trên dữ liệu thực tế sẽ cần dựa thêm vào Phần 2, đặc biệt là bảng so sánh trên tập kiểm tra, đường cong chọn λ , phân tích phần dư của mô hình tốt nhất và phân tích mức độ quan trọng của biến.

PHẦN 2

Ứng Dụng Data Fitting vào Dữ Liệu Thực

4 Mô Tả Bộ Dữ Liệu

4.1 Lý Do Lựa Chọn

Bộ dữ liệu **Air Quality Data in India** được lựa chọn cho đề án vì đáp ứng đầy đủ các tiêu chí của mô hình hồi quy và phân tích thống kê đa biến:

- **Kích thước mẫu lớn ($n \geq 200$):** Tập dữ liệu gốc chứa hàng chục nghìn quan sát (trên 29,000 dòng theo từng ngày tại các thành phố), vượt xa yêu cầu tối thiểu, giúp phản ánh đầy đủ và khách quan thực trạng ô nhiễm không khí, từ đó mang lại kết quả phân tích đáng tin cậy
- **Đa dạng đặc trưng ($p \geq 3$):** Dữ liệu bao gồm 16 biến số, trong đó có 12 biến định lượng phản ánh chi tiết nồng độ các chất gây ô nhiễm hóa học khác nhau (PM2.5, PM10, CO, NOx,...), rất phù hợp để xây dựng mô hình hồi quy đa biến và phân tích đa cộng tuyến
- **Hiện diện giá trị khuyết thiếu (Missing values $\geq 5\%$):** Bộ dữ liệu có tỉ lệ khuyết thiếu tự nhiên khá cao ở nhiều cột (lên đến trên 30% ở một số biến như NH3, PM10, Xylene) do sự cố cảm biến hoặc không có trạm đo. Điều này tạo không gian lý tưởng để thực hành các kỹ thuật xử lý dữ liệu thiếu
- **Biến mục tiêu liên tục:** Chỉ số chất lượng không khí (AQI) là một biến liên tục, hoàn toàn đáp ứng yêu cầu của bài toán hồi quy tuyến tính
- **Nguồn dữ liệu uy tín:** Dữ liệu được tổng hợp từ Hệ thống Giám sát Không khí Quốc gia Ấn Độ (CPCB) và được công bố công khai trên nền tảng khoa học dữ liệu Kaggle, đảm bảo tính thực tiễn và độ chuẩn xác cao

4.2 Tổng Quan Dataset

Dưới đây là các thông tin tổng quan nhất về tập dữ liệu được sử dụng:

- **Tên dataset:** Air Quality Data in India (2015-2020)
- **Nguồn:** Nền tảng Kaggle (URL: <https://www.kaggle.com/datasets/rohanrao/air-quality-data-in-india>) (tệp city_day.csv)
- **Số quan sát (n):** 29,531 dòng (đại diện cho dữ liệu các ngày từ 2015 đến 2020)
- **Số lượng biến (p):** 16 biến (bao gồm 2 biến định danh, 13 biến định lượng và 1 biến phân loại)
- **Biến mục tiêu (Target variable):** AQI (Air Quality Index) - Biến liên tục thể hiện chỉ số chất lượng không khí
- **Tỉ lệ Missing trung bình:** Khoảng 15% - 25% (biến động tùy theo từng chất ô nhiễm, cao nhất lên tới hơn 60% ở cột Xylene)


4.3 Mô Tả Các Biến

Bảng 18: Danh sách các biến trong bộ dữ liệu Air Quality Data in India (2015 - 2020)

Biến	Kiểu	Đơn vị	Mô tả	Missing
City	object	-	Tên thành phố được thu thập dữ liệu	0.0%
Date	datetime	-	Ngày quan trắc (YYYY-MM-DD)	0.0%
PM2.5	float64	$\mu g/m^3$	Nồng độ hạt bụi mịn (kích thước $\leq 2.5\mu m$)	$\approx 15.5\%$
PM10	float64	$\mu g/m^3$	Nồng độ hạt bụi (kích thước $\leq 10\mu m$)	$\approx 37.7\%$
NO	float64	$\mu g/m^3$	Nồng độ Nitric Oxide	$\approx 12.1\%$
NO2	float64	$\mu g/m^3$	Nồng độ Nitrogen Dioxide	$\approx 12.1\%$
NOx	float64	ppb	Nồng độ các oxit của Nitơ	$\approx 14.1\%$
NH3	float64	$\mu g/m^3$	Nồng độ Amoniac	$\approx 34.9\%$
CO	float64	mg/m^3	Nồng độ Carbon Monoxide	$\approx 6.9\%$
SO2	float64	$\mu g/m^3$	Nồng độ Lưu huỳnh Dioxide	$\approx 13.0\%$
O3	float64	$\mu g/m^3$	Nồng độ Ozone	$\approx 13.6\%$
Benzene	float64	$\mu g/m^3$	Nồng độ Benzen	$\approx 19.0\%$
Toluene	float64	$\mu g/m^3$	Nồng độ Toluen	$\approx 27.2\%$
Xylene	float64	$\mu g/m^3$	Nồng độ Xylen	$\approx 61.3\%$
AQI	float64	-	Chỉ số chất lượng không khí (Biến mục tiêu)	$\approx 15.8\%$
AQI_Bucket	object	-	Phân loại chất lượng (Good, Moderate, Severe,...)	$\approx 15.8\%$

4.4 Phân Phối Biến Mục Tiêu

Biến mục tiêu AQI (Air Quality Index) có miền giá trị từ 0 trở lên. Dựa vào trực quan hóa dữ liệu ban đầu, có thể rút ra một số nhận xét quan trọng về phân phối của biến này:



Hình 13: Phân phối biến mục tiêu AQI cho thấy dữ liệu lệch phải và chứa nhiều ngoại lai

- **Tính lệch phải (Right-skewed):** Phân phối của AQI bị lệch phải rất mạnh. Phần lớn các ngày có chỉ số AQI tập trung ở dải giá trị từ 50 đến 200 (mức độ từ tốt đến kém).
- **Hiện tượng ngoại lai (Outliers):** Đuôi phân phối kéo dài về bên phải với nhiều giá trị cực trị (có thể lên tới trên 800). Đây là những ngày ô nhiễm không khí ở mức "Nghiêm trọng". Các giá trị này tuy là "ngoại lai" về mặt thống kê nhưng lại là những hiện tượng thời tiết có thật và rất quan trọng trong bài toán dự đoán
- **Hướng xử lý:** Do phân phối không tuân theo phân phối chuẩn, để mô hình hồi quy tuyến tính OLS hoạt động hiệu quả và tránh vi phạm giả định về phần dư, ta cần cân nhắc thực hiện các phép biến đổi (ví dụ: Log-transform: $\ln(\text{AQI})$ hoặc Box-Cox transform) ở bước Tiền xử lý dữ liệu sắp tới.

5 Phương Pháp

5.1 Khảo Sát Dữ Liệu (EDA)

Mục tiêu của giai đoạn khảo sát dữ liệu (Exploratory Data Analysis – EDA) là phân tích và hiểu bộ dữ liệu `city_day.csv` ở trạng thái thô ban đầu, trước khi thực hiện bất kỳ bước tiền xử lý nào. Thông qua việc phân tích hình học phân phối, mức độ nhiễu và tương quan giữa các biến, từ đó đưa ra các quyết định xử lý dữ liệu có cơ sở khoa học cho các bước tiếp theo

5.1.1 Thống Kê Mô Tả

Bước đầu tiên, dữ liệu được nạp từ file `city_day.csv`, chuyển đổi cột `Date` về định dạng `datetime` và sắp xếp theo thứ tự (`City`, `Date`) nhằm đảm bảo tính liên tục theo thời gian cho từng thành phố. Thực hiện bước này như sau:

```
1 df_raw = pd.read_csv('data/city_day.csv')
2 df_raw['Date'] = pd.to_datetime(df_raw['Date'])
3 df_raw = df_raw.sort_values(by=['City', 'Date'])
```

Tiếp theo, bảng thống kê mô tả được tính toán cho tất cả các biến số, bao gồm các đại lượng: `count`, `mean`, `std`, `min`, Q_1 (25%), Q_2 (50% – median), Q_3 (75%), `max` và `median`

	PM2.5	PM10	NO	NO2	NOx	NH3
count	24933.000000	18391.000000	25949.000000	25946.000000	25346.000000	19203.000000
mean	67.450578	118.127103	17.574730	28.560659	32.309123	23.483476
std	64.661449	90.605110	22.785846	24.474746	31.646011	25.684275
min	0.040000	0.010000	0.020000	0.010000	0.000000	0.010000
25%	28.820000	56.255000	5.630000	11.750000	12.820000	8.580000
50%	48.570000	95.680000	9.890000	21.690000	23.520000	15.850000
75%	80.590000	149.745000	19.950000	37.620000	40.127500	30.020000
max	949.990000	1000.000000	390.680000	362.210000	467.630000	352.890000
median	48.570000	95.680000	9.890000	21.690000	23.520000	15.850000

Hình 14: Bảng thống kê mô tả các biến số trong bộ dữ liệu gốc

CO	SO2	O3	Benzene	Toluene	Xylene	AQI
27472.000000	25677.000000	25509.000000	23908.000000	21490.000000	11422.000000	24850.000000
2.248598	14.531977	34.491430	3.280840	8.700972	3.070128	166.463581
6.962884	18.133775	21.694928	15.811136	19.969164	6.323247	140.696585
0.000000	0.010000	0.010000	0.000000	0.000000	0.000000	13.000000
0.510000	5.670000	18.860000	0.120000	0.600000	0.140000	81.000000
0.890000	9.160000	30.840000	1.070000	2.970000	0.980000	118.000000
1.450000	15.220000	45.570000	3.080000	9.150000	3.350000	208.000000
175.810000	193.860000	257.730000	455.030000	454.850000	170.370000	2049.000000
0.890000	9.160000	30.840000	1.070000	2.970000	0.980000	118.000000

Hình 15: Bảng thống kê mô tả các biến số trong bộ dữ liệu gốc


Nhận xét: Quan sát bảng thống kê mô tả (Hình ?? và Hình 15), một số đặc điểm nổi bật cần được lưu ý:

- **Mức độ thiếu dữ liệu không đồng đều:** Số lượng quan sát hợp lệ (count) khác nhau đáng kể giữa các biến. Chẳng hạn, biến CO có 27472 giá trị hợp lệ, trong khi Xylene chỉ có 11422, cho thấy tỷ lệ missing values phân bố không đều và cần được xử lý cẩn thận
- **Khoảng cách lớn giữa trung vị và giá trị cực đại:** Đặc biệt ở các biến bụi (PM2.5, PM10), họ khí Nitơ (NOx) và chỉ số mục tiêu AQI, khoảng cách giữa trung vị và giá trị lớn nhất là rất lớn. Ví dụ, AQI có median = 118 nhưng max = 2049, gấp hơn 17 lần. Điều này báo hiệu sự xuất hiện của các điểm ngoại lai và phân phối lệch phải
- **Độ lệch chuẩn lớn:** Các biến như PM10 (std $\approx$ 90,6, mean $\approx$ 118,1), AQI (std $\approx$ 140,7, mean $\approx$ 166,5) có hệ số biến thiên cao, phản ánh sự biến động mạnh trong dữ liệu


5.1.2 Phân Phối và Phát Hiện Outliers

Để kiểm chứng giả thuyết về sự tồn tại của Outliers được rút ra từ bảng thống kê mô tả, nhóm tiến hành vẽ **cặp biểu đồ Histogram – Boxplot** cho toàn bộ các biến số trong bộ dữ liệu


```
1 for i, col in enumerate(num_cols_raw):
2     data = df_raw[col].dropna()
3     axes[i, 0].hist(data, bins=40, ...) # Histogram
4     axes[i, 1].boxplot(data, vert=False, ...) # Boxplot
```




Hình 16: Biểu đồ Histogram và Boxplot cho các biến số




Hình 17: Biểu đồ Histogram và Boxplot cho các biến số




Hình 18: Biểu đồ Histogram và Boxplot cho các biến số




Hình 19: Biểu đồ Histogram và Boxplot cho các biến số



Hình 20: Biểu đồ Histogram và Boxplot cho các biến số



Hình 21: Biểu đồ Histogram và Boxplot cho các biến số



Hình 22: Biểu đồ Histogram và Boxplot cho các biến số

Nhận xét: Kết quả trực quan hóa (Hình 16, Hình 17, Hình 18, Hình 19, Hình 20 và Hình 21, Hình 22) cho thấy:


- **Phân phối lệch phải nghiêm trọng:** Hầu hết các biến hóa chất (PM2.5, PM10, NO, CO, SO2, Benzene, Toluene, Xylene) và biến mục tiêu AQI đều có phân phối **lệch phải mạnh**. Điều này có ý nghĩa quan trọng: nếu áp dụng trực tiếp mô hình hồi quy tuyến tính OLS trên dữ liệu gốc, các giả định về phân phối chuẩn của phần dư sẽ bị vi phạm. Do đó ta phải dùng phép biến đổi để tiền xử lý dữ liệu
- **Outliers xuất hiện phổ biến:** Biểu đồ Boxplot cho thấy tất cả các biến số đều chứa outliers, thể hiện qua các điểm nằm ngoài phạm vi. Đặc biệt, AQI và PM2.5 có số lượng outliers rất lớn ở phía giá trị cao
- **Quyết định xử lý:** Dựa trên phân tích trên, nhóm quyết định không loại bỏ outliers,

vì chúng phản ánh các sự kiện ô nhiễm thực tế có ý nghĩa vật lý. Thay vào đó, sử dụng phương pháp chuẩn hóa bền vững (**RobustScaler**: $(x - \text{median})/\text{IQR}$) và biến đổi Logarit để giảm thiểu ảnh hưởng của outliers lên mô hình

5.1.3 Ma Trận Tương Quan

Để đánh giá mối quan hệ tuyến tính giữa các biến và phát hiện nguy cơ **đa cộng tuyến**, ma trận hệ số tương quan được tính toán và trực quan hóa bằng biểu đồ heatmap:

```
1 corr_matrix = df_raw[num_cols_raw].corr()
2 sns.heatmap(corr_matrix, annot=True, cmap='RdBu_r', ...)
```



Hình 23: Heatmap ma trận tương quan Pearson giữa các biến số

Nhận xét: Từ Hình 23, có thể rút ra các nhận định sau:


- **Tương quan cao trong họ khí Nitơ:** Các biến NO, NO2 và NOx có hệ số tương quan cặp rất cao. Điều này hoàn toàn phù hợp với bản chất hóa học: $\text{NOx} = \text{NO} + \text{NO}_2$, nên sự cộng tuyến giữa chúng là tất yếu

- **Tương quan giữa họ hợp chất hữu cơ:** Cặp biến Benzene–Toluene cũng thể hiện tương quan dương đáng kể, phản ánh nguồn phát thải chung từ phương tiện giao thông và hoạt động công nghiệp
- **Tương quan với biến mục tiêu:** Biến AQI có tương quan dương mạnh nhất với PM2.5 và PM10, xác nhận rằng bụi mịn là nhân tố chi phối chính đến chỉ số chất lượng không khí khoa học về ô nhiễm khí quyển
- **Hệ quả đối với mô hình:** Sự tồn tại của đa cộng tuyến cao sẽ khiến ma trận $(X^T X)^{-1}$ trong OLS trở nên suy biến(ill-conditioned), làm phương sai của các hệ số β tăng mạnh. Vấn đề này sẽ được giải quyết bằng **hồi quy Ridge** (điều chuẩn L_2) thay vì loại bỏ biến, nhằm bảo toàn thông tin dự báo

5.1.4 Phân Tích Missing Values

Phân tích tỷ lệ thiếu dữ liệu là bước quan trọng để lựa chọn chiến lược xử lý phù hợp. Nhóm tính toán tỷ lệ missing cho từng biến và trực quan hóa bằng biểu đồ horizontal bar chart:

```
1 missing_pct = df_raw[num_cols_raw].isnull().mean() * 100
2 missing_pct = missing_pct[missing_pct > 0].sort_values()
3 missing_pct.plot.barh(...)
```



Hình 24: Tỷ lệ thiếu dữ liệu theo từng biến trong bộ dữ liệu gốc

Nhận xét: Hình 24 cho thấy:

- **Phân bố tỷ lệ thiếu không đồng đều:** Một số biến có tỷ lệ thiếu rất cao, đặc biệt là Xylene (khoảng 60%), PM10, NH3 (khoảng 30–35%). Trong khi đó, các biến như CO, NO, NO2 có tỷ lệ thiếu thấp hơn đáng kể
- **Cơ chế thiếu dữ liệu:** Dựa vào đặc thù của dữ liệu quan trắc môi trường, cơ chế thiếu được đánh giá chủ yếu là **MAR** (Missing At Random) — nghĩa là việc thiếu dữ liệu có thể phụ thuộc vào các biến quan sát được khác (ví dụ: một số trạm quan trắc không đo đủ tất cả các chỉ tiêu)
- **Chiến lược xử lý:** Do tỷ lệ thiếu cao và cơ chế MAR, phương pháp **Regression Imputation** (thay thế giá trị thiếu bằng giá trị dự đoán từ mô hình hồi quy OLS dựa trên các biến còn lại) được lựa chọn thay cho các phương pháp đơn giản như thay bằng trung bình/trung vị. Ngoài ra, các **Missing Indicator** (cờ chỉ báo thiếu dữ liệu) được thêm vào như biến phụ trợ, cho phép mô hình học được mẫu hình thiếu dữ liệu nếu nó mang thông tin dự báo

5.1.5 Tổng Kết Giai Đoạn EDA

Qua quá trình khảo sát dữ liệu, các phát hiện chính có thể tóm tắt như sau:

1. Phân phối các biến hóa chất và AQI bị **lệch phải mạnh**, cần biến đổi để giảm độ lệch
2. **Outliers** xuất hiện phổ biến nhưng phản ánh sự kiện thực tế, không nên loại bỏ mà cần sử dụng phương pháp chuẩn hóa bền vững (RobustScaler)
3. **Đa cộng tuyến** giữa các biến hóa chất là tất yếu; giải pháp là sử dụng hồi quy Ridge thay vì loại bỏ biến
4. **Missing values** phân bố không đều, cần Regression Imputation kết hợp Missing Indicator

Các phát hiện này định hướng toàn bộ chiến lược tiền xử lý và lựa chọn mô hình ở các phần tiếp theo

5.2 Tiền Xử Lý Dữ Liệu

Dựa trên các phát hiện từ giai đoạn EDA, nhóm đã thiết kế lớp AirQualityPipeline để tự động hóa toàn bộ quy trình tiền xử lý dữ liệu. Pipeline được thiết kế theo nguyên tắc **White-box**: mọi phép biến đổi đều minh bạch, có thể kiểm chứng, và tuân thủ nghiêm

ngặt nguyên tắc fit trên tập huấn luyện transform trên cả tập huấn luyện và tập kiểm tra nhằm tránh rò rỉ dữ liệu

5.2.1 Xử Lý Missing Values

Như đã phân tích ở phần EDA, tỷ lệ thiếu dữ liệu trong bộ dữ liệu gốc là rất đáng kể và phân bố không đồng đều giữa các biến (Xylene $\sim$ 60%, PM10 $\sim$ 30%). Phương pháp đơn giản như thay bằng trung bình hoặc trung vị sẽ làm mất mối tương quan giữa các biến, gây ra sai lệch trong mô hình hồi quy.

Do đó, nhóm đã lựa chọn phương pháp **Regression Imputation**: với mỗi biến có giá trị thiếu, một mô hình OLS được huấn luyện từ các biến còn lại để dự đoán giá trị bị thiếu

```
1 for col in self.cols_with_missing:
2     missing_mask = X_num[col].isna()
3     other_cols = [c for c in cols if c != col]
4     # ... chuẩn bị dữ liệu huấn luyện ...
5     X_b = [[1.0] + row for row in X_train]
6     beta_hat, _ = ols_fit(X_b, y_train)
7     self.impute_models[col] = (other_cols, beta_hat)
8     # Dự đoán giá trị missing
9     preds = matmul(X_pred_b, beta_mat)
10    X_filled.loc[missing_mask, col] = [row[0] for row in preds]
```

Ngoài ra, cho mỗi biến có dữ liệu thiếu, một **Missing Indicator** được tạo thêm, cho phép mô hình học được mẫu hình thiếu dữ liệu nếu nó mang thông tin dự báo:

```
1 for col in self.cols_with_missing:
2     indicator_df[f'missingindicator_{col}'] = X_num[col].isna().astype(float)
```

Nhận xét:

- Phương pháp Regression Imputation bảo toàn mối tương quan giữa các biến, khác biệt so với mean/median imputation hoặc kNN imputation
- Nguyên tắc fit-transform được tuân thủ nghiêm ngặt: mô hình OLS cho imputation chỉ được huấn luyện trên tập train (`_impute_fit_transform`), sau đó áp dụng hệ số đã học lên tập test (`_impute_transform`), tránh rò rỉ dữ liệu
- Trong trường hợp mô hình OLS không thể huấn luyện, hệ thống tự động fallback sang thay thế bằng trung vị:

```
1 except Exception:
2     self.impute_models[col] = None
```

```
3 X_filled.loc[missing_mask, col] = self.impute_medians[col]
```


5.2.2 Xử lý Outliers

Như đã chỉ ra trong phần EDA, hầu hết các biến hóa chất đều có phân phối **lệch phải mạnh**. Điều này vi phạm giả định phân phối chuẩn của phần dư trong mô hình OLS, đồng thời khiến các giá trị cực trị có ảnh hưởng quá lớn đến hệ số hồi quy



Giải pháp được áp dụng là phép biến đổi **Logarit** sử dụng hàm $\log(1+x)$ ($\log1p$), đảm bảo giá trị 0 được ánh xạ về 0 (tránh lỗi $\log(0) = -\infty$). Trước khi áp dụng log, các giá trị âm (nếu có, do imputation) được cắt về 0 bằng phương thức `clip`:



```
1 X_num_imputed = X_num_imputed.clip(lower=0)
2 for col in self.skewed_cols:
3     if col in X_num_imputed.columns:
4         X_num_imputed[col] = X_num_imputed[col].apply(math.log1p)
```


Danh sách các biến được áp dụng biến đổi logarit (`skewed_cols`) bao gồm: PM2.5, PM10, NO, NOx, NH3, CO, Benzene, Toluene, Xylene, AQI_Yesterday, PM2.5_Yesterday.



Hình 25: Phân phối các biến số sau phép biến đổi Logarit ($\log1p$)

Hình 26: Phân phối các biến số sau phép biến đổi Logarit ($\log_{1p}$)Hình 27: Phân phối các biến số sau phép biến đổi Logarit ($\log_{1p}$)

Hình 28: Phân phối các biến số sau phép biến đổi Logarit ($\log_{1p}$)Hình 29: Phân phối các biến số sau phép biến đổi Logarit ($\log_{1p}$)



Hình 30: Phân phối các biến số sau phép biến đổi Logarit ($\log_{1p}$)

Nhận xét: Có thể thấy phép biến đổi logarit đã làm giảm đáng kể mức độ lệch phải của các biến hóa chất. Phân phối sau biến đổi gần với dạng chuẩn, đáp ứng tốt hơn các giả định của mô hình hồi quy tuyến tính

5.2.3 Chuẩn Hóa Dữ Liệu

Sau khi xử lý missing values và biến đổi logarit, bước tiếp theo là chuẩn hóa dữ liệu. Chuẩn hóa là bắt buộc trước khi áp dụng hồi quy Ridge, vì hệ số phạt $\lambda \|\beta\|_2^2$ trong hàm mục tiêu Ridge sẽ phạt không công bằng nếu các biến có đơn vị và thang đo khác nhau

Thay vì sử dụng z-score chuẩn ($x' = \frac{x - \mu}{\sigma}$) — dễ bị ảnh hưởng bởi outliers qua giá trị trung bình μ và độ lệch chuẩn σ — nhóm đã chọn **RobustScaler**:

$$x' = \frac{x - \text{median}(x)}{\text{IQR}(x)}$$

trong đó $\text{IQR} = Q_3 - Q_1$ là khoảng tứ phân vị. Phương pháp này bền vững trước outliers vì sử dụng trung vị và IQR thay cho trung bình và độ lệch chuẩn

```
1 # Fit (chỉ trên tập train)
2 def _scale_fit(self, X):
3     self.scale_medians = X.median()
4     q1 = X.quantile(0.25)
5     q3 = X.quantile(0.75)
6     self.scale_iqrs = q3 - q1
7     self.scale_iqrs = self.scale_iqrs.replace(0, 1.0)
8
9 # Transform (áp dụng cho cả train và test)
10 def _scale_transform(self, X):
11     return (X - self.scale_medians) / self.scale_iqrs
```

Nhận xét: Trường hợp đặc biệt $IQR = 0$ (biến không có biến thiên giữa Q_1 và Q_3) được xử lý bằng cách thay bằng 1.0 để tránh lỗi chia cho 0

5.2.4 Feature Engineering

Ngoài các biến số hóa chất, bộ dữ liệu còn chứa hai biến cần xử lý đặc biệt: Date (ngày tháng) và City (tên thành phố).

Biến thời gian - Cyclical Encoding: Biến Date được chuyển đổi thành cặp đặc trưng tuần hoàn (cyclical features) bằng hàm sin và cos theo tháng, phản ánh tính chu kỳ của mùa:

$$\text{Month_sin} = \sin\left(\frac{2\pi \cdot m}{12}\right), \quad \text{Month_cos} = \cos\left(\frac{2\pi \cdot m}{12}\right)$$

trong đó m là chỉ số tháng. Phương pháp này đảm bảo tháng 12 và tháng 1 được biểu diễn là “gần nhau” trong không gian đặc trưng, phù hợp với bản chất tuần hoàn của dữ liệu khí hậu.


```
1 X_copy['Month_sin'] = month.apply(  
2     lambda x: math.sin(2 * math.pi * x / 12))  
3 X_copy['Month_cos'] = month.apply(  
4     lambda x: math.cos(2 * math.pi * x / 12))
```

Biến phân loại - One-Hot Encoding: Biến City được nhóm thành top 5 thành phố có nhiều quan sát nhất và nhóm “Other”, sau đó áp dụng One-Hot Encoding với tham số drop_first=True để tránh bẫy biến giả:

```
1 self.top_cities = X['City'].value_counts().nlargest(5).index.tolist()  
2 X_copy['City_Grouped'] = X_copy['City'].apply(  
3     lambda c: c if c in self.top_cities else 'Other')  
4 cat_encoded = pd.get_dummies(  
5     X_prep[['City_Grouped']], drop_first=True, dtype=float)
```

5.2.5 Tổng Quan Pipeline

Toàn bộ quy trình tiền xử lý được đóng gói trong lớp AirQualityPipeline, thực hiện tuần tự các bước sau khi gọi fit_transform(X) trên tập huấn luyện:



Hình 31: Quy trình tiền xử lý dữ liệu trong AirQualityPipeline

Kết quả:

- Sau giai đoạn tiền xử lý dữ liệu, ta thu được ma trận dữ liệu gồm 33 cột: 14 biến số gốc + 12 missing indicators + 2 biến thời gian tuần hoàn + 5 biến one-hot cho thành phố

	PM2.5	PM10	NO	NO2	NOx	NH3	CO	SO2
15510	-1.446386	-1.207868	-0.520296	-0.497123	-1.446348	-1.412761	-1.176372	-0.557018
11096	0.466081	1.115661	0.713783	0.965478	0.252866	-0.519104	-0.733853	3.256579
23436	-0.913632	-0.171570	0.656297	-0.375144	0.402868	-0.302813	0.801214	1.533991

Hình 32: Ma trận đặc trưng sau khi tiền xử lí dữ liệu

O3	Benzene	...	missingindicator_Benzene	missingindicator_Toluene	missingindicator_Xylene
-0.131763	-0.719062	...	0.0	0.0	-1.0
0.639280	0.063068	...	0.0	0.0	0.0
-0.722781	-0.626740	...	0.0	1.0	0.0

Hình 33: Ma trận đặc trưng sau khi tiền xử lí dữ liệu

Month_sin	Month_cos	City_Grouped_Chennai	City_Grouped_Delhi	City_Grouped_Hyderabad
-0.5	-0.866025	0.0	0.0	1.0
0.5	-0.866025	0.0	1.0	0.0
0.5	-0.866025	0.0	0.0	0.0

Hình 34: Ma trận đặc trưng sau khi tiền xử lí dữ liệu

City_Grouped_Lucknow	City_Grouped_Other
0.0	0.0
0.0	0.0
0.0	1.0

Hình 35: Ma trận đặc trưng sau khi tiền xử lí dữ liệu

5.3 Xây Dựng Mô Hình

Mục tiêu cốt lõi của phần này là thiết lập và tinh chỉnh các thuật toán học máy nhằm dự báo chính xác AQI. Thay vì sử dụng trực tiếp các thư viện máy học được đóng gói sẵn,

toàn bộ quy trình huấn luyện trong đề án này được xây dựng thủ công và triển khai có hệ thống, tuân thủ chặt chẽ nguyên tắc đi từ cơ bản đến nâng cao

Cụ thể, tiến trình bắt đầu với OLS để thiết lập mức hiệu suất cơ sở và phát hiện các vấn đề tiềm ẩn trong dữ liệu, điển hình là hiện tượng đa cộng tuyến. Dựa trên các chẩn đoán đó, tập biến độc lập sẽ được chọn lọc và tối ưu hóa nhằm loại bỏ nhiễu. Tiếp theo, các thuật toán nâng cao hơn như Điều chuẩn L2 và học Bayes sẽ được áp dụng để kiểm soát rủi ro quá khớp. Cuối cùng, phương pháp Kernel RBF được sử dụng để giải quyết các mối quan hệ phi tuyến phức tạp của hóa học trong bầu khí quyển Để đảm bảo tính khách quan khi đánh giá hiệu suất, dữ liệu (sau khi tiền xử lý) được chia thành hai tập độc lập:

- **Tập huấn luyện:** Chiếm 80% số lượng quan sát. Mô hình chỉ sử dụng tập dữ liệu này để học các quy luật và tính toán trọng số
- **Tập kiểm thử:** Chiếm 20% còn lại. Tập dữ liệu này được giữ hoàn toàn tách biệt trong suốt quá trình huấn luyện, đóng vai trò như môi trường thực tế để đánh giá khả năng dự báo của mô hình trên dữ liệu mới

Bên cạnh đó, để đảm bảo tính tái lập — yếu tố bắt buộc để bất kỳ ai chạy lại code cũng ra cùng một kết quả — tham số `random_state = 42` được cố định trong tất cả các khâu chia mẫu. Mã nguồn thực thi quy trình này được minh họa tại Đoạn mã bên dưới:

```
1 # Phân tách biến mục tiêu (AQI) và ma trận đặc trưng (X)
2 y = df['AQI']
3 X = df.drop(columns=['AQI', 'AQI_Bucket', 'Date', 'City'])
4 # Cố định random_state để đảm bảo tính tái lập của mô hình
5 X_train, X_test, y_train, y_test = train_test_split(
6     X, y,
7     test_size=0.20,
8     random_state=42
9 )
10 print(f"Kích thước tập Huấn luyện: {X_train.shape}")
11 print(f"Kích thước tập Kiểm thử: {X_test.shape}")
```

Với bộ dữ liệu đã được phân chia nhất quán, chúng ta sẽ lần lượt đi vào triển khai và phân tích chi tiết từng mô hình.

5.3.1 Mô Hình 1 — OLS Cơ Bản

Mô hình đầu tiên được triển khai thử nghiệm là OLS. Tạm thời chưa thực hiện chọn lọc, mô hình này sử dụng toàn bộ không gian đặc trưng sau khi đã hoàn tất quy trình tiền xử

lý Nhằm tuân thủ nguyên tắc xây dựng thuật toán từ cơ sở của đề án, quá trình tối ưu hóa trọng số không sử dụng các hàm gói gọn từ thư viện scikit-learn. Thay vào đó, hàm `ols_fit()` được lập trình thủ công hoàn toàn bằng Python và đại số tuyến tính từ Phần 1 đã được import và thực thi trực tiếp:

```
1 # Nạp hàm ols_fit tự xây dựng từ module ols_implementation (Phần 1)
2 from ols_implementation import ols_fit
3 # Huấn luyện mô hình tìm ma trận trọng số và phương sai phân dư
4 beta_ols, sigma2_ols = ols_fit(X_tr_mat, y_tr_god_arr)
```

Sau khi xác định được bộ trọng số $\hat{\beta}$, bước tiếp theo là chẩn đoán rủi ro đa cộng tuyến — một hiện tượng tất yếu khi nạp quá nhiều biến vào mô hình OLS. VIF đã được tính toán cho từng đặc trưng. Dưới đây là kết quả từ Console ghi nhận các cảnh báo đáng chú ý ($VIF > 5$):

```
1 KẾT QUẢ VIF
2 CẢNH BÁO (>5) - Biến PM2.5 : VIF = 8.72
3 CẢNH BÁO (>5) - Biến PM10 : VIF = 5.18
4 CẢNH BÁO (>5) - Biến AQI_Yesterday : VIF = 6.69
5 CẢNH BÁO (>5) - Biến PM2.5_Yesterday : VIF = 9.03
```

Theo tiêu chuẩn thống kê học cổ điển, các biến có $VIF > 5$ được xem là có sự tương quan tuyến tính tương đối lớn nhưng không quá nghiêm trọng ($VIF > 10$) và thường bị khuyến cáo gạch bỏ khỏi mô hình nếu có thể để tránh làm phình sai số chuẩn của hệ số hồi quy. Tuy nhiên, **căn cứ vào đặc thù của dữ liệu Môi trường, nhóm đã quyết định giữ lại toàn bộ 4 biến trên**. Các lí do mà nhóm đưa ra như sau:

- **Cơ sở hình thành AQI:** Các hạt bụi mịn $PM_{2.5}$ và PM_{10} là những tác nhân có tỷ trọng cao nhất tác động trực tiếp vào phương trình tính toán AQI thực tế tại Ấn Độ. Việc loại bỏ chúng chỉ để làm đẹp thông số thống kê sẽ phá vỡ hoàn toàn bản chất cốt lõi của mô hình
- **Đặc tính tự hồi quy:** Trong khí quyển, bụi mịn và khói mù hiếm khi tiêu tán lập tức mà có tính chất được tích tụ qua từng ngày. Do đó, các biến trễ như $AQI_Yesterday$ và $PM_{2.5_Yesterday}$ hiển nhiên sẽ có sự tương quan cộng tuyến cực mạnh với biến hiện tại, đẩy giá trị VIF lên cao. Tuy vậy, lượng thông tin từ quá khứ mà chúng mang lại là chìa khóa tối quan trọng để bắt được đà của xu hướng ô nhiễm

Từ kết quả chẩn đoán trên, nhóm đã rút ra một nguyên tắc quan trọng: Quá trình chọn lọc đặc trưng không thể chỉ dựa dẫm một cách máy móc vào các quy tắc toán học, mà bắt buộc phải đối chiếu với kiến thức chuyên ngành Tóm lại, 4 biến quan trọng kể trên

được giữ lại dựa trên cơ sở kiến thức chuyên ngành. Tuy nhiên, vì mô hình OLS cơ bản đang sử dụng toàn bộ các biến hiện có, nó chắc chắn vẫn chứa đựng nhiều biến nhiễu không mang lại giá trị dự báo thực tế. Để khắc phục điều này và làm gọn mô hình, quy trình loại bỏ biến nhiễu sẽ được triển khai trong phần Mô hình 2 - OLS Chọn Biến tiếp theo

5.3.2 Mô Hình 2 — OLS Chọn Biến

Từ kết quả của Mô hình 1, có thể thấy việc sử dụng toàn bộ dữ liệu đầu vào khiến mô hình phải gánh thêm nhiều biến 'rác' (nhiều). Những biến này không có giá trị dự báo mà chỉ làm cho mô hình phức tạp thêm. Do đó, bước tiếp theo là phải rà soát và loại bỏ chúng dựa trên chỉ số P-Value (Mức ý nghĩa thống kê)

Để thực hiện việc này, thay vì dùng các thư viện tự động có sẵn, nhóm đã sử dụng lại hàm `coef_inference()` được lập trình từ Phần 1 nhằm tự tính toán sai số chuẩn và P-value của từng hệ số hồi quy dựa trên nền tảng Đại số Tuyến tính để xác định xem biến đó có thực sự tác động đến AQI hay không

Chỉ những đặc trưng thỏa mãn điều kiện $p\text{-value} < 0.05$ (tức là có sự đóng góp vào dự báo với độ tin cậy trên 95%) mới được phép giữ lại. Mã nguồn thực thi thuật toán chọn lọc như sau:

```
1 from ols_implementation import coef_inference, ols_fit
2 # Sử dụng hàm coef_inference từ Part 1 để lấy p-values
3 _, _, p_values, _, _ = coef_inference(X_tr_mat, y_tr_god_arr, beta_ols,
4                                     sigma2_ols)
5 # Đánh giá và lọc ra index các biến có mức ý nghĩa thống kê ( $p < 0.05$ )
6 selected_idx = np.where(np.array(p_values)[1:] < 0.05)[0]
7 # Tái cấu trúc ma trận thiết kế (ghép thêm cột Intercept) cho tập Train và Test
8 X_tr_sel = np.c_[np.ones((X_tr_proc.shape[0], 1)), X_tr_proc[:, selected_idx]]
9 X_te_sel = np.c_[np.ones((X_te_proc.shape[0], 1)), X_te_proc[:, selected_idx]]
10 # Huấn luyện lại OLS trên không gian ma trận đã được tinh gọn
11 beta_ols_sel, _ = ols_fit(X_tr_sel, y_tr_god_arr)
```

Mã nguồn 12: Thuật toán trích xuất P-Value và tái cấu trúc ma trận đặc trưng

Kết quả của bộ lọc này đã tạo ra một cuộc sàng lọc đáng kể đối với tập dữ liệu đầu vào. Báo cáo từ hệ thống cho thấy như sau:

Sau khi loại bỏ lượng lớn biến nhiễu, mô hình **OLS Chọn Biến** được huấn luyện lại trên không gian chỉ còn 19 chiều. Kết quả đánh giá trên tập kiểm thử vô cùng tích cực với hệ

số xác định đạt $R^2 = 0.8869$. Mặc dù bị cắt giảm gần một nửa số lượng đặc trưng đầu vào, mô hình vẫn duy trì khả năng giải thích xấp xỉ 89% sự biến thiên của biến mục tiêu AQI. Điều này chứng tỏ rằng quá trình chọn lọc P-value đã hoạt động cực kỳ hiệu quả: mô hình trở nên gọn nhẹ hơn, chuẩn xác hơn, tiết kiệm chi phí tính toán phần cứng và hạn chế tối đa rủi ro overfitting từ các dữ liệu rác

5.3.3 Mô Hình 3 — Hồi Quy Ridge với Kiểm Chứng Chéo

Ở Mô hình 1, chúng ta đã quyết định giữ lại các biến cốt lõi như PM2.5 hay AQI_Yesterday để bảo toàn ý nghĩa vật lý của bài toán, chấp nhận rủi ro hiện tượng đa cộng tuyến với VIF cao. Giờ đây, **hồi quy Ridge** sẽ là giải pháp triệt để cho vấn đề này. Bằng cách cộng thêm một ma trận phạt λI vào phương trình tối ưu gốc, hồi quy Ridge sẽ thu hẹp độ lớn và phương sai của các hệ số hồi quy, giúp kiểm soát sự bất ổn định do đa cộng tuyến sinh ra **mà không cần phải bỏ đi bất kỳ biến số quan trọng nào**.


Tuy nhiên, thách thức lớn nhất khi áp dụng hồi quy Ridge là phải tìm ra cường độ điều chuẩn λ phù hợp nhất. Nếu λ quá nhỏ, mô hình sẽ vô dụng và quay về OLS thông thường; nếu λ quá lớn, các hệ số hồi quy sẽ bị ép về gần 0 (chịu hình phạt quá mức), dẫn đến hiện tượng độ chệch cao và làm mô hình đánh mất năng lực dự báo. Để giải bài toán này một cách khách quan, kỹ thuật **Kiểm chứng chéo K-lần** với $K = 5$ đã được triển khai.

Để đảm bảo đúng yêu cầu tự xây dựng thuật toán của đề án, toàn bộ vòng lặp kiểm chứng chéo K-lần và thuật toán hồi quy Ridge đều không dùng viện trợ từ bên ngoài, mà được gọi từ chính các module Đại số Tuyến tính tự lập trình ở Phần 1:

```
1 from cross_validation import ridge_cv_score
2 from ridge_lasso import ridge_fit
3 # ... Vòng lặp quét qua dải phân bố các giá trị lambda ...
4 # Đánh giá sai số MSE của từng lambda bằng hàm tự code kiểm chứng chéo K-lần
5 mse_cv = ridge_cv_score(X_tr_mat, y_tr_god_arr, k=5, lam=lam)
6 # Sau khi tìm được lambda cực tiểu hóa sai số, tiến hành fit trọng số
7 beta_ridge_final = ridge_fit(X_tr_mat, y_tr_god_arr, best_lambda)
```

Mã nguồn 13: Thuật toán tự code để dò tìm lambda và huấn luyện hồi quy Ridge

Quá trình dò tìm đã quét qua một dải các giá trị λ . Như minh họa tại Hình 36, đường cong kiểm chứng chéo K-lần cho thấy sai số RMSE trung bình trên các tập xác thực giảm dần và đạt giá trị thấp nhất tại $\lambda^* = 5.0$, sau đó bắt đầu tăng ngược trở lại do bị phạt quá mạnh do mô hình kém khớp



Hình 36: Biểu đồ kiểm chứng chéo K-Fold. Đường đứt nét màu đỏ biểu thị tham số điều chuẩn tối ưu $\lambda = 5.0$, tương ứng với điểm cực tiểu của sai số RMSE

Với tham số $\lambda = 5.0$ tối ưu nhất, ma trận trọng số cuối cùng $\hat{\beta}_{\text{ridge}}$ được huấn luyện thành công. Đánh giá trên tập kiểm thử độc lập cho thấy mô hình đạt hệ số xác định vô cùng xuất sắc với $R^2 = 0.8871$.

Kết quả cho thấy việc sử dụng hồi quy Ridge là một giải pháp hoàn toàn chính xác. Thay vì trong trường hợp phải xóa bỏ các biến quan trọng như PM2.5 hay PM10 để tránh lỗi đa cộng tuyến, ta đã giữ lại được chúng nhằm duy trì ý nghĩa thực tế của bài toán. Đồng thời, sự bất ổn định của mô hình do các biến này gây ra đã được xử lý triệt để nhờ thuật toán điều chuẩn L2 của Ridge

5.3.4 Mô Hình 4 — Bayesian


Sau khi đã giải quyết được vấn đề rác nhiễu (bằng OLS Chọn biến) và lỗi đa cộng tuyến (bằng Ridge), chúng ta đối mặt với một thách thức mới mang tính bản chất của Khí tượng học: **Sự rủi ro và độ bất định**. Bụi mịn và chỉ số AQI thường xuyên có những đợt bùng phát dị biệt do các yếu tố ngẫu nhiên (như sự thay đổi đột ngột của hướng gió, cháy rừng, bão...). Các mô hình dự báo điểm như OLS hay Ridge chỉ có thể đưa ra một con số cứng nhắc duy nhất mà không hề cho biết "con số đó đáng tin cậy đến mức nào". Đó là lý do **Hồi quy tuyến tính Bayesian** được đưa vào hệ thống. Thay vì cố gắng tìm ra một bộ trọng số β cố định duy nhất, phương pháp Bayesian coi β là một *biến ngẫu nhiên* tuân theo các phân phối xác suất. Cách hoạt động của thuật toán này rất linh hoạt: Ban đầu, nó tự đưa ra một khoảng ước lượng sơ bộ (dựa trên các thiết lập alpha). Khi được tiếp xúc và học hỏi từ dữ liệu thực tế, mô hình sẽ liên tục tự điều chỉnh và thu hẹp dần khoảng ước lượng đó lại để đưa ra dự báo cuối cùng. Đặc biệt, mô hình này được lập trình tay

hoàn toàn bằng Toán học xác suất từ module `advanced_methods`:

```
1 from advanced_methods import BayesianLinearRegression
2 # Huấn luyện Bayesian với alpha=1.0 và beta=10.0
3 bayes_model = BayesianLinearRegression(alpha=1.0, beta=10.0).fit(X_tr_df,
4     y_tr_god)
5 # Lấy cả giá trị dự báo trung bình và độ bất định cho từng điểm dữ liệu
6 y_te_pred_bayes, y_te_std_bayes = bayes_model.predict(X_te_df)
```

Mã nguồn 14: Khởi tạo và huấn luyện mô hình Bayesian

Sức mạnh thực sự của mô hình này không nằm ở hệ số xác định ($R^2 = 0.8872$, xấp xỉ mức xuất sắc của Ridge), mà nằm ở khả năng **lượng hóa rủi ro**. Như minh họa trong biểu đồ dưới đây, ngoài đường dự báo trung bình, thuật toán còn vẽ ra một **Khoảng Tin cậy được bôi màu xanh**.



Hình 37: Dự báo Bayesian. Dải màu xanh thể hiện biên độ rủi ro của dự báo tại từng thời điểm

Ý nghĩa của dải các khoảng tin cậy này trong thực tiễn:

- Ở những ngày thời tiết ổn định, dải xanh thu hẹp lại rất sát với đường dự báo trung bình, thể hiện sự tự tin cao của thuật toán.
- Ngược lại, tại các đỉnh ô nhiễm dị biệt chưa từng xuất hiện trong quá khứ, dải xanh lập tức phình to ra. Mô hình lúc này đang cảnh báo với rằng: *"Tại điểm này, dữ liệu quá bất thường, dự báo có rủi ro sai số rất lớn"*

Dưới góc độ ứng dụng thực tiễn, một mô hình có khả năng định lượng và cảnh báo độ bất định như Bayesian mang lại giá trị rất lớn cho việc hoạch định chính sách môi trường. Nó giúp các nhà quản lý môi trường xây dựng được các kịch bản dự phòng hiệu quả, thay vì chỉ phụ thuộc vào một con số dự báo đơn lẻ — vốn tiềm ẩn rủi ro sai lệch nghiêm trọng khi thời tiết có biến động dị biệt

5.3.5 Mô Hình 5 — Kernel RBF

Bốn mô hình trước đó (OLS cơ bản, OLS Chọn biến, Ridge và Bayesian) dù sở hữu cấu trúc toán học chặt chẽ và ưu việt, song vẫn không thể vượt qua một điểm yếu chí mạng: **bản chất tuyến tính**. Về mặt hình học, chúng chỉ có thể tạo ra các "mặt phẳng" cứng nhắc để khớp với dữ liệu. Đối với những ngày thời tiết bình thường, mặt phẳng này hoạt động rất tốt. Tuy nhiên, khi đối mặt với các **đỉnh ô nhiễm dị biệt** vọt lên đột ngột, đường dự báo tuyến tính gần như chững lại, mất hoàn toàn khả năng phản ứng và khó khăn trong việc bám sát các cực trị

Để phá vỡ rào cản tuyến tính mà không gây quá tải năng lực tính toán (do việc phải khai triển đa thức thủ công), nhóm đã áp dụng **mẹo hạt nhân**. Cụ thể, **hàm nhân RBF** được sử dụng để ánh xạ ngầm dữ liệu gốc lên một không gian đặc trưng vô hạn chiều. Tại không gian đa chiều này, sự tương quan giữa các biến trở nên phân tách rõ ràng. Cơ chế toán học này cho phép mô hình thiết lập một đường dự báo phi tuyến cực kỳ linh hoạt, đủ sức uốn cong và bám sát chính xác các đỉnh ô nhiễm dị biệt

Tiếp tục tuân thủ nguyên tắc xây dựng thuật toán từ cơ sở, class `KernelRidgeRegression` được lập trình hoàn toàn dựa trên nền tảng đại số tuyến tính (giải hệ phương trình chứa ma trận hạt nhân K). Đồng thời, kỹ thuật tìm kiếm lưới được triển khai nhằm xác định tổ hợp tham số tối ưu nhất giữa λ và γ :

```
1 from advanced_methods import KernelRidgeRegression
2 # Quét qua các tổ hợp để tìm ra cặp siêu tham số tốt nhất
3 for l in lambdas:
4     for g in gammas:
5         # Huấn luyện mô hình tự code bằng Kernel Trick
6         krr = KernelRidgeRegression(lam=l, gamma=g)
7         krr.fit(X_tr_mat, y_tr_arr)
8
9     # ... Lọc ra cặp tham số cho sai số xác thực thấp nhất ...
```

Mã nguồn 15: Khởi tạo và dò tìm siêu tham số cho Kernel RBF

Kết quả trả về đã tạo ra một bước nhảy vọt về hiệu suất so với toàn bộ các mô hình trước đó: Hệ số xác định trên tập kiểm thử đạt mức cao kỷ lục $R^2 = 0.9189$ (giải thích gần 92% sự biến thiên của không khí).

```
1 Cấu hình RBF tối ưu: gamma = 0.005, lambda = 0.1
2 R^2 của RBF: 0.9189
```


6 Kết Quả và Đánh Giá

6.1 Bảng So Sánh Các Mô Hình

Sau khi hoàn tất quá trình huấn luyện và tối ưu hóa, 5 mô hình được đưa lên bàn cân để đánh giá hiệu suất dự báo trên tập kiểm thử — phần dữ liệu hoàn toàn độc lập mà thuật toán chưa từng được nhìn thấy. Các chỉ số đo lường bao gồm MAE, RMSE và hệ số xác định R^2

Bảng 19: Tổng hợp và So sánh hiệu suất của 5 mô hình trên tập Test


Mô hình	MAE	RMSE	R^2	Không gian Biến
1. OLS Cơ bản	22.897	44.650	0.8872	33
2. OLS Chọn biến	22.918	44.716	0.8869	19 (Lọc P-value)
3. Ridge CV ($\lambda = 5$)	22.906	44.674	0.8871	33 (Điều chuẩn L2)
4. Bayesian Tuyến tính	22.897	44.650	0.8872	33 (Xác suất)
5. Kernel RBF	18.822	37.859	0.9189	Vô hạn chiều

Nhận xét Đánh giá: Nhìn vào Bảng 19, ta có thể rút ra những kết luận sau:

- **Giới hạn của các mô hình Tuyến tính:** Bốn mô hình đầu tiên gồm OLS, Ridge và Bayesian cho ra kết quả gần như tương đương nhau ($R^2 \approx 0.887$). Điều này chứng tỏ chúng ta đã đạt đến giới hạn dự báo của không gian tuyến tính đối với bộ dữ liệu này. Dù áp dụng kỹ thuật điều chuẩn hay mô hình xác suất, bản chất của phương trình bậc nhất vẫn không đủ độ linh hoạt để bám sát các phân bố dữ liệu phức tạp. Mặc dù vậy, việc *Mô hình 2 - OLS Chọn biến* (chỉ sử dụng 19 đặc trưng) duy trì được hiệu suất xấp xỉ *Mô hình 1* (33 đặc trưng) là một minh chứng rõ nét cho tính hiệu quả của quá trình tinh giản không gian biến
- **Sự ưu việt của Kernel RBF:** Bằng cách phá vỡ rào cản tuyến tính, phương pháp Kernel RBF tạo ra một sự nâng cấp toàn diện về hiệu suất. Sai số RMSE giảm mạnh từ 44.65 xuống mức 37.859, đồng thời hệ số R^2 đạt 0.9189. Khả năng ánh xạ dữ liệu sang chiều không gian mới đã giúp Kernel RBF trở thành mô hình tối ưu nhất của đề án, đáp ứng trọn vẹn tiêu chí về độ chính xác lẫn khả năng phản ứng với các cực trị thời tiết

6.2 Phân Tích Tầm Quan Trọng Đặc Trưng

Bên cạnh việc tối ưu hóa các chỉ số đo lường hiệu suất, khả năng giải thích của mô hình là một yêu cầu cốt lõi trong phân tích dữ liệu thực. Thông qua việc phân tích ma trận trọng số β từ mô hình Ridge (khi phương sai của các hệ số đã được kiểm soát chặt chẽ nhờ điều chuẩn L2), chúng ta có thể định lượng được mức độ tác động của từng yếu tố lên chỉ số AQI



Hình 38: Đo lường mức độ tác động của Đặc trưng lên chỉ số AQI bằng trọng số Ridge


Biểu đồ 38 làm nổi bật hai quy luật dữ liệu quan trọng sau đây:

- **Nhóm các Tác nhân Chính:** AQI_Yesterday và PM2.5 là hai đặc trưng đóng vai trò chi phối mức độ lớn của giá trị dự báo. Kết quả này hoàn toàn trùng khớp với cơ sở lý thuyết, phản ánh đúng công thức tính toán AQI thực tế của CPCB Ấn Độ (trong đó PM2.5 là thành phần quyết định), đồng thời chứng minh đặc tính tích tụ của khói mù trong khí quyển
- **Vai trò Hiệu chỉnh của các Biến Khuyết thiếu:** Đáng chú ý nhất là missingindicator_PM2.5 mang trọng số âm với giá trị tuyệt đối rất lớn. Thuật toán đã tự nhận diện được quy luật: khi cảm biến lỗi (không có dữ liệu PM2.5), phương pháp nội suy trung bình có thể dẫn đến hiện tượng đánh giá vượt mức. Để cân bằng lại, mô hình tự động gán một trọng số âm cho biến chỉ báo này, đóng vai trò như một cơ chế hiệu chỉnh nhằm hạ mức dự báo AQI về ngưỡng thực tế. Đây là một cơ chế tối ưu toán học mang tính phòng ngừa rủi ro cực kỳ hiệu quả

6.3 Phân Tích Phần Dư - Mô Hình Kernel RBF

Hiệu suất R^2 cao chỉ là điều kiện cần, một mô hình dự báo chỉ thực sự vững chắc khi phần dư của nó thỏa mãn các giả định thống kê cốt lõi. Để đánh giá toàn diện cơ chế nội tại của Kernel RBF, 8 biểu đồ chẩn đoán phần dư đã được triển khai.

Chẩn đoán Phần dư (Residual Diagnostics) - Mô hình Tối ưu Kernel RBF



Hình 39: 8 biểu đồ chẩn đoán phần dư của Kernel RBF

Phân tích chuyên sâu từ các biểu đồ:

- **Kỳ vọng sai số và phương sai đồng đều (Biểu đồ 1 - 7):** Biểu đồ phần dư theo giá trị dự báo (1) cho thấy các quan sát phân tán ngẫu nhiên và đối xứng qua trục hoành


($y = 0$) mà không hình thành các cấu trúc đường cong, chứng tỏ dự báo của mô hình là không chệch và đã hấp thụ tốt các quy luật phi tuyến. Để cô lập và thẩm định độc lập biên độ phân tán, biểu đồ *quy mô-vị trí* (7) được áp dụng thông qua phép biến đổi toán học $\sqrt{|\text{phần dư}|}$ nhằm ánh xạ toàn bộ sai số lên mặt phẳng dương. Sự gia tăng biên độ phân tán tại góc phải của cả hai biểu đồ (khu vực $AQI > 800$) đã phản ánh một đặc tính thống kê chung: Sự tồn tại của hiện tượng phương sai phần dư không đồng đều cục bộ khi mô hình đối mặt với các mức độ ô nhiễm cực đại.

- **Đặc tính Phân phối của Phần dư (Biểu đồ 2 & 3):** Biểu đồ *tần suất* (3) thể hiện sai số có độ nhọn cao và hội tụ chặt chẽ quanh mốc 0, khẳng định độ chính xác vượt trội của hệ thống trong điều kiện thời tiết thông thường. Tuy nhiên, sự phân kỳ ở hai đầu của đường *Biểu đồ Q-Q* (2) cho thấy hiện tượng phân phối đuôi dày, tức mô hình vẫn ghi nhận mức sai số nhất định khi đối mặt với các sự kiện khí hậu cực đoan hiếm gặp
- **Mức độ Hội tụ Dự báo (Biểu đồ 4):** Trong khi phần lớn các biểu đồ khác tập trung phân tích đặc tính phân phối của sai số, biểu đồ *thực tế-dự báo* (4) đóng vai trò bổ trợ thiết yếu nhằm đối chiếu trực tiếp giữa giá trị thực tế và giá trị dự báo. Sự xuất hiện của tập hợp điểm hội tụ chặt chẽ dọc theo đường chéo lý tưởng $y = x$ cung cấp cơ sở trực quan quan trọng để minh họa cho hệ số xác định $R^2 = 0.9189$. Biểu đồ này là một thành phần không thể thiếu nhằm đánh giá khách quan mức độ bám sát thực tế và năng lực tổng quát hóa của thuật toán Kernel RBF
- **Kiểm định tính độc lập của Phần dư (Biểu đồ 5 & 6):** Hai biểu đồ này kết hợp để xác định xem sai số dự báo có tính ngẫu nhiên hay bị lặp lại theo thời gian, tức hiện tượng tự tương quan. Quan sát trực quan trên biểu đồ *Chuỗi phần dư* (5), các sai số phân tán khá ngẫu nhiên mà không hình thành các chu kỳ hay xu hướng hệ thống. Tuy nhiên, khi kiểm định chặt chẽ bằng toán học qua biểu đồ *ACF* (6), một số vạch độ trễ vẫn vượt ra khỏi dải ranh giới đứt nét an toàn. Về mặt vật lý, hiện tượng này phản ánh chính xác đặc tính của không khí: khối bụi ô nhiễm không tan biến ngay lập tức. Do đó, mô hình đôi khi chưa bắt kịp tốc độ phân tán chậm của bão bụi, dẫn đến việc sai số dự báo của ngày hôm trước ít nhiều vẫn kéo dài và ảnh hưởng sang ngày hôm sau. Dẫu vậy, mức độ phụ thuộc này là khá nhỏ và hoàn toàn nằm trong giới hạn cho phép đối với một mô hình dữ liệu môi trường thực chứng
- **Tính bền vững của cấu trúc mô hình (Biểu đồ 8):** Biểu đồ *Khoảng cách Cook* (8) được sử dụng để định lượng mức độ tác động của từng quan sát đơn lẻ lên toàn bộ phương trình dự báo. Theo lý thuyết thống kê, một điểm dữ liệu sẽ bị cảnh báo là ngoại lai có ảnh hưởng nếu giá trị khoảng cách vượt qua ngưỡng an toàn $4/n$ (đường

đứt nét, với n là kích thước mẫu dữ liệu). Phân tích biểu đồ cho thấy có một số ít các điểm dữ liệu vượt qua ranh giới này. Tuy nhiên, mức độ phân tán của chúng là không đáng kể khi giá trị cực đại chỉ chạm mốc 0.02. Trong Khoa học Dữ liệu, cấu trúc của một mô hình chỉ thực sự bị bẻ cong và biến dạng khi Khoảng cách Cook chạm ngưỡng nguy hiểm ($D_i > 0.5$ hoặc 1.0). Việc các ngoại lai lớn nhất cũng chỉ dừng lại ở biên độ (0.02) là minh chứng rõ nét cho thấy tập dữ liệu đã được tinh chuẩn kỹ lưỡng; thuật toán Kernel RBF duy trì được tính bền vững tuyệt đối và hoàn toàn miễn nhiễm trước các sai số dị biệt

6.4 Phân Tích Tầm Quan Trọng Đặc Trưng

Cuối cùng, để chốt lại lý do tại sao Kernel RBF được chọn làm mô hình để triển khai thực tiễn, chúng ta cần nhìn vào hành vi của nó trong môi trường rủi ro nhất: Các đợt bùng phát ô nhiễm



Hình 40: Trực quan khả năng bất định ô nhiễm

Như minh họa tại vùng bôi vàng trong Hình 40, các đợt bùng phát ô nhiễm dị biệt là phép thử phức tạp nhất đối với các mô hình. Tại vùng dữ liệu này, thuật toán tuyến tính Ridge phản ứng bằng cách ngoại suy trực tiếp các hệ số, bám sát cực trị một cách khá ấn tượng. Dẫu vậy, nếu xét trên bình diện toàn bộ không gian dữ liệu, đặc tính cứng nhắc của phương trình bậc nhất vẫn không mang lại hiệu suất tối ưu.

Trái lại, Kernel RBF chứng minh sự ưu việt thông qua cơ chế phi tuyến cục bộ. Khi đối mặt với cực trị đột biến, thuật toán chủ động giới hạn biên độ dự báo nhằm ngăn chặn rủi ro quá khớp. Việc chấp nhận một mức sai lệch nhỏ tại chính đỉnh cực đoan đã tạo điều

kiện cho mô hình RBF duy trì sự ổn định, từ đó bám sát quỹ đạo dữ liệu một cách toàn diện và mượt mà hơn ở hàng ngàn điểm dữ liệu khác. Cơ sở toán học của hành vi này chính là sự đánh đổi độ chệch–phương sai, nhân tố cốt lõi giúp mô hình RBF tối thiểu hóa triệt để RMSE.

7 Kết Luận

7.1 Tóm Tắt Kết Quả

7.1.1 Phần 1 - Data Fitting

Trong Phần 1, nhóm đã tự cài đặt các hàm toán học phục vụ cho hồi quy tuyến tính

- Các phép toán ma trận cơ bản: nhân ma trận (`matmul`), chuyển vị (`transpose`), nghịch đảo (`inverse`), đơn vị (`identity`), và giải hệ phương trình bằng phương pháp Gradient liên hợp (`cg_solve`)
- Hồi quy OLS: hàm `ols_fit()` tính ước lượng $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ cùng với suy diễn hệ số (`coef_inference`) bao gồm t -statistic, p -value và khoảng tin cậy
- Hồi quy Ridge và Lasso: hàm `ridge_fit()` với nghiệm dạng đóng $\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$ và thuật toán Coordinate Descent cho Lasso
- Cross-validation: hàm `kfold_cv()` và `ridge_cv_score()` để đánh giá chéo K-fold ($k = 5$)
- Phân tích phần dư: VIF (Variance Inflation Factor), Cook's Distance, và bộ biểu đồ chẩn đoán 8 panel

Toàn bộ kết quả đầu ra của thư viện tự cài đặt đã được kiểm chứng và cho kết quả tương đương với các thư viện chuẩn

7.1.2 Phần 2 - Ứng dụng Data Fitting vào dữ liệu thực tế

Trong Phần 2, nhóm đã áp dụng data fitting vào bài toán dự báo chỉ số AQI, sử dụng bộ dữ liệu `city_day.csv`. Quy trình bao gồm: phân tích khám phá dữ liệu, thiết kế pipeline tiền xử lý tự động, và huấn luyện 5 mô hình hồi quy. Kết quả so sánh hiệu suất trên tập test được tóm tắt trong Bảng 20

Bảng 20: Tóm tắt hiệu suất các mô hình trên tập test

Mô hình	MAE	RMSE	R^2 (test)
OLS Cơ bản	22.897	44.650	0.8872
OLS Chọn biến	22.918	44.716	0.8869
Ridge ($\lambda^* = 5$)	22.906	44.674	0.8871
Bayesian Tuyến tính	22.897	44.650	0.8872
Kernel RBF	18.822	37.859	0.9189

Mô hình Kernel RBF (với $\gamma = 0,005$, $\lambda = 0,1$) đạt hiệu suất tốt nhất, với $R^2 \approx 0,92$ trên tập test, vượt trội đáng kể so với nhóm 4 mô hình tuyến tính ($R^2 \approx 0,89$). Kết quả này cho thấy mối quan hệ giữa các biến ô nhiễm và chỉ số AQI mang bản chất **phi tuyến**, và việc ánh xạ dữ liệu lên không gian đặc trưng bậc cao thông qua hàm nhân RBF giúp mô hình nắm bắt được các tương tác phức tạp mà hồi quy tuyến tính không thể biểu diễn

7.2 Bài Học Rút Ra

7.2.1 Về lý thuyết

- **OLS và tính chất BLUE:** Theo định lý Gauss–Markov, ước lượng OLS là ước lượng tuyến tính không chệch tốt nhất (BLUE — Best Linear Unbiased Estimator). Tuy nhiên, thực nghiệm cho thấy khi dữ liệu tồn tại đa cộng tuyến mạnh ($VIF > 10$ ở nhiều biến), phương sai của các hệ số OLS tăng đáng kể, khiến mô hình trở nên không ổn định
- **Điều chuẩn L2 (Ridge):** Ridge Regression giải quyết vấn đề đa cộng tuyến bằng cách thêm nhân tử phạt $\lambda \|\boldsymbol{\beta}\|_2^2$ vào hàm mục tiêu. Tuy nhiên, với bộ dữ liệu này, hiệu quả cải thiện của Ridge so với OLS là không đáng kể (R^2 : 0.8871 vs 0.8872), cho thấy đa cộng tuyến ảnh hưởng chủ yếu đến phương sai hệ số chứ không ảnh hưởng nhiều đến khả năng dự báo tổng thể
- **Phi tuyến và Kernel Method:** Bước nhảy về hiệu suất từ các mô hình tuyến tính ($R^2 \approx 0,89$) sang Kernel RBF ($R^2 \approx 0,92$) khẳng định rằng các hiện tượng hóa học trong khí quyển (phản ứng quang hóa, kết tụ bụi mịn) tuân theo quy luật phi tuyến. Hàm nhân RBF $K(\mathbf{x}, \mathbf{x}') = e^{-\gamma \|\mathbf{x} - \mathbf{x}'\|^2}$ cho phép mô hình hóa các tương tác này mà không cần xác định dạng hàm phi tuyến cụ thể

7.2.2 Về thực tiễn

- **Tầm quan trọng của tiền xử lý:** Giai đoạn tiền xử lý dữ liệu đóng vai trò quyết định đến chất lượng mô hình. Khi chúng ta hiểu rõ bộ dữ liệu của mình, ta có thể áp dụng các phương pháp tiền xử lý phù hợp, từ đó giúp mô hình cho kết quả tốt hơn
- **Bài học về rò rỉ dữ liệu:** Khi làm sạch dữ liệu, một nguyên tắc cực kỳ quan trọng mà nhóm rút ra được là phải phân chia rõ ràng giữa tập train và tập test. Mọi thao tác tính toán từ việc lấy số trung vị để điền khuyết cho đến việc tính khoảng tứ phân vị (IQR) để chuẩn hóa đều phải được học từ tập train rồi mới áp dụng sang tập test

7.3 Hướng Mở Rộng

Nếu có thêm thời gian để tiếp tục phát triển đề án, nhóm dự kiến sẽ mở rộng theo một số hướng sau:

1. **Thử nghiệm Elastic Net:** Giúp mô hình vừa tự động loại bỏ các biến nhiễu vừa giữ cho các hệ số hồi quy ổn định hơn
2. **Thêm yếu tố chuỗi thời gian:** Đưa thêm các biến trễ (như chỉ số AQI của vài ngày trước đó) để mô hình tận dụng được tính liên tục của dữ liệu
3. **Thử nghiệm các mô hình học máy mới:** Chạy thử dữ liệu trên các thuật toán mạnh mẽ hơn như Random Forest, XGBoost hay Neural Network để so sánh hiệu quả

8 Tài liệu tham khảo

- [1] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning*. Springer, 2nd edition, 2021.
- [2] MathWorks. Why fit a curve to the data? YouTube Video, 2022. <https://www.youtube.com/watch?v=WizuZhN8B60>.
- [3] Gilbert Strang. *Introduction to Linear Algebra*. Wellesley-Cambridge Press, 6th edition, 2023.
- [4] Khan Academy. Least squares approximation. YouTube Video, 2022. <https://www.youtube.com/watch?v=MC7l96tW8V8>.
- [5] Garud Iyengar, Henry Lam, and Tianyu Wang. Is cross-validation the gold standard to estimate out-of-sample model performance? *arXiv preprint arXiv:2407.02754*, 2024.
- [6] CodeXplore. Hướng dẫn trực quan hoá dữ liệu với seaborn và python. YouTube Video, 2022. https://www.youtube.com/watch?v=4_YB4ZWLgPg&t=61s.

A Mã Nguồn Chính

Link Repository: https://github.com/ChickenDev-cyber/Project2_TUDTK.git

B Cấu Trúc Thư Mục

Group_02/

```
|-- README.md                # Hướng dẫn chạy và tái lập kết quả nhanh
|-- requirements.txt         # Danh sách thư viện Python cần cài đặt
|-- report/                 # Thư mục chứa báo cáo PDF hoàn chỉnh
|   |-- report.pdf           # Báo cáo chính thức dạng PDF
|   |-- compile_report/     # Thư mục chứa mã nguồn LaTeX để biên dịch
|       |-- figures/        # Chứa các đồ thị xuất ra từ Notebooks
|       |-- part1/
|       |-- part2/
|       |-- 0_covers.tex
|       |-- 0_foreword.tex
|       |-- 0_members.tex
|       |-- overview.tex
|       |-- appendix.tex
|       |-- tailieu.bib
|       |-- main.tex
|-- part1/
|   |-- matrix_ops.py        # Thư viện đại số tuyến tính tự cài đặt từ đầu
|   |-- ols_implementation.py
|   |-- ridge_lasso.py
|   |-- residual_analysis.py
|   |-- cross_validation.py
|   |-- part1_notebook.ipynb
|   |-- test_part1_unit.py    # Kiểm thử đơn vị cho các thuật toán Phần 1
|-- part2/
|   |-- data/
|       |-- city_day.csv      # Tập dữ liệu chất lượng không khí thực tế
|       |-- data_pipeline.py
|       |-- model_comparison.py
|       |-- advanced_methods.py # Hồi quy Bayes và Kernel Ridge nâng cao
|       |-- part2_notebook.ipynb
```



```
|  |-- test_part2_unit.py    # Kiểm thử đơn vị cho pipeline và mô hình
```